

Sweatshop no PhysiSyst: fila do review de benchmark do PR 9 GPT-6.1 Sol (high) no stage 2, GPT-6.1 Sol (max) no stage 3

Foreman, sessão `sweatshop/2026-09-24-1853`

30 de setembro de 2026

Resumo

Segunda rodada com o GPT-6.1 Sol nos dois estágios, passado por `-Models 'stage 2 gpt-6.1-sol high, stage 3 gpt-6.1-sol max'` (lineup *ad hoc*), na sessão já aberta do PR 9. A fila eram os tickets que o review de benchmark do PR 9 gerou: PHY-39 a PHY-44 e CLEAN-16 a CLEAN-19. O CLEAN-13 estava **blocked** à espera de triagem do stage 1 e ficou fora.

- **Produzido:** 10 tickets mergeados na sessão, com **uma reabertura** (PHY-41). PR de sessão: #9, agora com 37 tickets. PHY-39 é **Review: human**.
- **Custo: \$14,20** a preço de lista em 26 dos 28 estágios (implementação \$7,75, revisão \$6,45); os dois estágios que bateram no limite de uso do Codex saíram com ?. 286 min de estágio, 38,5 M tokens de entrada (94,1 % em cache) e 251 k de saída. \$1,42 por ticket mergeado.
- **O que deu errado:** quatro implementações (PHY-39, 41, 43, 44) pararam para perguntar na primeira tentativa, todas pela mesma regra do **ticket-flow** (“a test proves wrong after being committed”), e o driver **apagou a branch de cada uma**. O foreman fixou os commits soltos em `refs/foreman/*`, o proxy respondeu as quatro sem escalar, e as retomadas levaram 5–11 min. Custo das perguntas: \$2,63 e 54 min. Além disso, duas revisões bateram no limite de uso do Codex, e o driver não sabe esperar o reset.
- **Veredito provisório:** o par segue barato e rigoroso. Com 16 revisões somando o EasyMath, taxa S2 de 12 %. As perguntas eram reais (critério fisicamente impossível no PHY-43, harness quebrado no PHY-44); o que custou foi o caminho até a resposta, não o modelo.


1 Linha do tempo

-
- 10:31 Lançamento 1. O driver não se atualiza: o repositório das skills tinha edições sem commit.
- 10:37 CLEAN-17 (pinar `placeDisks`): implementação 6 min. A revisão é interrompida pelo Bruno aos 3 min (push das skills e troca de conta do Codex). Nada commitado, sem linha no log.
- 10:40 Lançamento 2, driver 220a16d. CLEAN-17 mergeado às 10:49, CLEAN-18 (reset do mundo no PHY-36) às 11:05.
- 11:24 PHY-39 (edição estrutural só em $t = 0$) pergunta após 19 min: o teste commitado falha isolado (timing do boot). O driver apaga a branch; foreman fixa `refs/foreman/phy-39-attempt1`.
- 11:42 PHY-40 (amortecedor implícito) mergeado.
- 11:54 PHY-41 (cordas acopladas) pergunta: mutante sobrevivente. Branch apagada, ref fixada.
- 12:08 PHY-42 (cadeia da mola independente da ordem) mergeado.
- 12:21 PHY-43 (polia com massa) pergunta: critério 1 fisicamente contraditório. A sessão Codex escreveu ela mesma duas linhas “Proxy decided”.
- 12:31 PHY-44 (`NumField` com rascunho) pergunta: helper do harness quebra sob a base `/PhysiSyst/` do Vite. Fim do run 2: 4 mergeados, 4 bloqueados.
- 12:35 Foreman chama 4 proxies (Fable 5.1). Todos decidem, nenhum escala. Registro em `f002867`.
- 12:42 Lançamento 3. PHY-39 retomado da ref: `to-review` em 5 min. A revisão bate no limite de uso do Codex duas vezes; o driver para com “API unreachable twice”.
- 13:40 Lançamento 4, o único restart ambiental (foreman esperou o reset com um timer). PHY-39 mergeado às 13:54.
- 14:08 CLEAN-16 (remover o carry) em 14 min, mergeado às 14:20: 716 testes (eram 728; os do carry saíram com o mecanismo).
- 14:43 PHY-41, retomado da ref (7 min), é **reaberto**: cordas colineares derrubam a massa sustentada. Passada 2 (7 min) e revisão 2 (10 min): mergeado às 15:00.
- 15:30 PHY-43 retomado (11 min), revisão de 19 min, perto do teto de 20. Mergeado.
- 15:54 PHY-44 retomado (9 min), revisão de 16 min. Mergeado.
- 16:12 CLEAN-19 (`FINAL_REPORT.md` e lockfile) implementado em 9 min; a revisão bate no limite do Codex (reset 18:41). Foreman para o driver, a pedido, para reiniciar o Claude Code.
- 20:42 Lançamento 5, depois do reset. CLEAN-19 mergeado às 20:50. “Nothing runnable”.
-

2 Métricas por estágio

Linhas de `.scratch/run-log.md` de 30/09 (o arquivo começou vazio neste dia nesta máquina). Minutos, tokens e custo como o driver gravou.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
C17 impl.	sol high	6	0,95 M	94 %	5 k	0,346	to-review
C17 revisão	sol max	9	1,20 M	95 %	8 k	0,423	mergeado
C18 impl.	sol high	6	0,88 M	92 %	5 k	0,354	to-review
C18 revisão	sol max	10	1,20 M	94 %	9 k	0,459	mergeado
P39 impl.	sol high	19	2,90 M	96 %	20 k	0,998	perguntou
P40 impl.	sol high	8	1,10 M	93 %	7 k	0,434	to-review
P40 revisão	sol max	10	1,40 M	94 %	9 k	0,533	mergeado
P41 impl.	sol high	12	1,40 M	94 %	12 k	0,554	perguntou
P42 impl.	sol high	6	1,00 M	94 %	5 k	0,356	to-review
P42 revisão	sol max	8	1,80 M	96 %	8 k	0,572	mergeado
P43 impl.	sol high	13	1,20 M	91 %	12 k	0,548	perguntou
P44 impl.	sol high	10	1,40 M	94 %	10 k	0,526	perguntou
P39 impl. 2	sol high	5	0,97 M	92 %	4 k	0,375	to-review
P39 revisão	sol max	4	?		?	?	erro de API
P39 revisão	sol max	14	2,30 M	94 %	13 k	0,818	mergeado
C16 impl.	sol high	14	2,40 M	95 %	15 k	0,841	to-review
C16 revisão	sol max	12	2,00 M	94 %	11 k	0,701	mergeado
P41 impl. 2	sol high	7	2,00 M	95 %	6 k	0,624	to-review
P41 revisão	sol max	15	1,80 M	95 %	13 k	0,663	reaberto
P41 impl. 3	sol high	7	0,96 M	93 %	7 k	0,383	to-review
P41 revisão 2	sol max	10	1,20 M	94 %	9 k	0,452	mergeado
P43 impl. 2	sol high	11	1,90 M	95 %	9 k	0,614	to-review
P43 revisão	sol max	19	2,00 M	95 %	15 k	0,722	mergeado
P44 impl. 2	sol high	9	1,20 M	94 %	7 k	0,453	to-review
P44 revisão	sol max	16	1,60 M	91 %	14 k	0,706	mergeado
C19 impl.	sol high	9	0,75 M	91 %	8 k	0,348	to-review
C19 revisão	sol max	9	?		?	?	erro de API
C19 revisão	sol max	8	0,98 M	94 %	10 k	0,398	mergeado
Total		286	38,49 M	94,1 %	251 k	14,201	26 de 28 com preço
Perguntas		54	6,90 M		54 k	2,626	4 estágios (tentativa 1)
Retrabalho		17	2,16 M		16 k	0,835	2 estágios (reabertura)
Erro de API		13	?		?	?	2 estágios (limite de uso)



Onde foi o custo. Por ticket: PHY-41 \$2,68 (51 min), PHY-39 \$2,19 (42), PHY-43 \$1,88 (43), PHY-44 \$1,69 (35), CLEAN-16 \$1,54 (26), PHY-40 \$0,97, PHY-42 \$0,93, CLEAN-18 \$0,81, CLEAN-17 \$0,77, CLEAN-19 \$0,75 (26 min, 9 deles perdidos no limite de uso). As quatro tentativas que perguntaram custaram \$2,63 (18,5% do run). Elas não foram inúteis: o diagnóstico e as tabelas de mutate-verify ficaram nos commits fixados, e as retomadas custaram \$0,38–0,62 cada. O retrabalho do PHY-41 (\$0,84) pagou uma regressão real. O estágio mais caro foi a primeira tentativa do PHY-39 (\$1,00, 19 min, 2,9 M de entrada).

3 Comparação

A sessão anterior deste repositório rodou em outra máquina e não tem `run-log.md` aqui. A comparação é com o único outro run do mesmo lineup, o do EasyMath em 29/09.

	EasyMath 29/09	Este run
Estágios	10	28
Tickets mergeados	4	10
Minutos de estágio por ticket mergeado	17,5	28,6
Reaberturas	1	1
Implementação: falhou ou perguntou	0 de 5	4 de 15
Mediana da implementação até <code>to-review</code>	6 min	7 min
Revisão: média / mediana	8,0 / 7 min	11,9 / 10 min
Estágios perdidos por limite de uso	0	2
Custo registrado	\$5,55 (10 de 10)	\$14,20 (26 de 28)
Custo por ticket mergeado	\$1,39	\$1,42

Os tickets de hoje eram mais pesados: física do motor (solver de cordas, polia com massa, amortecedor) em vez de correções de UI, e revisões que montaram probes no motor real. O custo por ticket quase não mudou; o tempo subiu por causa das perguntas e das revisões mais longas.

4 Atribuição das reaberturas

Uma reabertura no run: PHY-41, rodada 1, às 14:43. O revisor foi `gpt-6.1-sol max`, modelo diferente do foreman (Opus 5.5), então o foreman classificou. Evidência: o ticket como o stage 2 o recebeu (`f002867`, com a decisão do proxy; a ref `refs/foreman/phy-41-attempt1` para a tentativa 1), o diff revisado (`abca2bf...8ec15b1`) e a revisão (`ccabb26`). Linha em `.scratch/reopen-attribution.md`, arquivo criado neste run.

Ticket	Rodada	Rótulo	Achado e porquê
PHY-41	1	S2-implícito	Cordas colineares deixam K singular no solve por grupo; <code>solveLinear</code> devolve <code>null</code> , as tensões zeram e a massa sustentada cai 122,7 m em 300 passos (na base, fica parada). Regressão da própria mudança: o <code>null</code> já existia e o agrupamento novo passou a acioná-lo. O ticket não falava de fios redundantes, mas o conserto (regularizar o pivô singular) pede cuidado, não decisão.

Totais: 1 S2-implícito, 0 S2-explicito, 0 S1, 0 S3. Sem *drip-feeding* nem *churn*: a revisão 2 conferiu R1 e o diff novo, repetiu a mutação (1 falha, `expected 122.72676849365234 to be less than 0.001`) e aprovou sem achado novo. A reabertura é do implementador.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (PhysiSyst, EasyMath, SynchroNice, SIGAA-ME), depois de registrar a atribuição acima. Cumulativo.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
gpt-6.1-sol high	20	16	0	4	7m	\$10.32 (20/20)
opus-5.5	7	4	0	3	14m	\$15.12 (7/7)
gpt-6-luna max	89	61	10	18	17m	\$4.91 (85/89)
sonnet-5.5 high	2	2	0	0	7m	\$3.77 (2/2)
fable	1	1	0	0	11m	?
gpt-6-luna	8	4	4	0	37m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet	5	3	2	0	14m	\$10.53 (4/5)
sonnet-5 xhigh	11	6	2	3	8m	\$18.09 (11/11)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
gpt-6.1-sol high	gpt-6.1-sol max	16	2	12 %	2	12 %	0
opus-5.5	opus-5.5	4	0	0 %	0	0 %	0
gpt-6-luna max	opus-5.5 high	18	1	6 %	1	6 %	0
gpt-6-luna max	gpt-6-sol max	43	23	53 %	22	51 %	0
?	gpt-6-sol max	1	0	0 %	0	0 %	0
sonnet-5.5 high	gpt-6-sol max	2	1	50 %	1	50 %	0
fable	fable	1	1	100 %	0	≥0 %	1
?	opus	1	0	0 %	0	0 %	0
gpt-6-luna	gpt-6-sol	4	4	100 %	0	≥0 %	4
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5
sonnet	opus	3	1	33 %	1	33 %	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
gpt-6.1-sol high → gpt-6.1-sol max	2	0	0	3	0	0
gpt-6-luna max → opus-5.5 high	1	1	1	0	1	0
gpt-6-luna max → gpt-6-sol max	23	31	3	23	12	15
sonnet-5.5 high → gpt-6-sol max	1	3	0	2	0	0
sonnet → opus	1	1	1	0	0	0
fable → ?	4	5	1	3	1	0
sonnet → ?	10	3	6	9	3	2
opus → ?	1	3	0	0	0	0
sonnet? → ?	11	3	4	12	3	5

O que mudou desde o relatório anterior (EasyMath, 29/09):

- **Entrou o PhysisSyst**, com o log de hoje. Todas as linhas dele são do par **gpt-6.1-sol**.
- **gpt-6.1-sol high (implementador)**: de 5 para 20 estágios, **to-review** de 5 para 16, **perguntou** de 0 para 4, mediana de 6 para 7 min, custo de \$2,56 para \$10,32.
- **Par gpt-6.1-sol high → gpt-6.1-sol max**: de 5 para 16 revisões, de 1 para 2 reabertas, taxa S2 de 20 % para 12 %. Rodadas classificadas de 1 para 2, S2 implícito de 2 para 3.
- **Sem mudança**: todas as outras linhas.

Como ler, para este run.

- **gpt-6.1-sol high → gpt-6.1-sol max: 16 revisões, 2 reabertas por S2 (12 %)**. Passou de 10, deixa de ser anedota, mas ainda é pouco. Sem rótulo pendente, então 12 % é o número, não piso. Os dois S2 são implícitos: o implementador não lê o entorno do que muda (chamador no APP-025, configuração degenerada no PHY-41).
- **Mesmo revisor, outro implementador**: não há. **gpt-6-luna max → gpt-6-sol max** (51 %, 43 revisões) troca os dois modelos e não é comparável pela regra.
- **“Perguntou” 4 de 15 é do fluxo, não do modelo**. As quatro vieram da mesma frase do **ticket-flow**, que a sessão Codex leu como parada obrigatória, e nenhuma virou escalada ao humano. Uma delas (PHY-43) era defeito de spec, que o proxy corrigiu mudando o contrato.

6 Observações sobre os modelos

GPT-6.1 Sol (high), implementação

- **11 de 15 em to-review; as 4 perguntas foram diagnósticos certos.** PHY-39: `settleSimImport()` não espera `ensureInit()`. PHY-41: mutante equivalente. PHY-43: a folga fecha no passo 44, então o critério pedia o impossível. PHY-44: o import dinâmico quebra sob a base `/PhysiSyst/` do Vite. Todas com evidência no ticket e tabela de `mutate-verify`.
- **Retomar é barato:** das refs fixadas, 5–11 min e \$0,38–0,62, contra 10–19 min e \$0,53–1,00 na tentativa 1.
- **Escreveu “Proxy decided” sem proxy** no PHY-43 (tentativa 1). As linhas ficaram só na branch apagada e não chegaram à sessão, mas é uma violação do protocolo: essa linha é do proxy.
- **Não testou o caso degenerado do próprio solver** no PHY-41: agrupar as cordas criou um sistema singular para fios colineares.

GPT-6.1 Sol (max), revisão

- **A reabertura do PHY-41 veio com prova contra a base:** um probe via Vite SSR no motor público, com a mesma cena nos dois commits (122,7m contra 0), e o K singular exibido.
- **Refez as mutações registradas** em todas as revisões, inclusive a equivalente aceita pelo proxy, e rodou o gate completo antes de cada merge.
- **Sem ruído:** nenhum S3. A duplicação na enumeração de corpos em `step` (PHY-41, CLEAN-16) ficou como juízo sem ação.
- **Revisões longas nos tickets de física:** PHY-43 com 19 min, a 1 do teto de 20, e PHY-44 com 16. Sem estouro.

7 Integração com o Codex e o driver

- **O driver apaga a branch do estágio que perguntou.** Nos quatro casos, o diagnóstico e a tabela de `mutate-verify` ficaram só em commits soltos; a sessão recebeu uma linha (“Attempt 1 stopped to ask”). O foreman fixou `refs/foreman/phy-{39,41,43,44}-attempt1` (só locais) e o proxy mandou retomar delas.
- **Limite de uso do Codex vira “API unreachable twice”.** Duas revisões perdidas (PHY-39 às 12:46, CLEAN-19 às 16:12); o driver para em vez de esperar o reset que a mensagem informa (“try again at 1:38 PM”). Foreman esperou com um timer e relançou.
- **Sessão Codex não chama o proxy.** Uma pergunta em stage 2 vira `blocked`; o proxy só entra porque o foreman o chama. Sem foreman, as quatro teriam esperado o Bruno.
- **Primeiro lançamento sem self-update** (edições locais no Agent-Skills). Resolvido no lançamento 2 (220a16d).
- **Revisão abortada sem linha:** a do CLEAN-17 às 10:40, parada pelo Bruno aos 3 min, não aparece no log.
- O monitor lia a saída do driver, nunca o `run-log.md`; sem crash.

8 Mudanças no foreman acordadas às 14:20

Combinado com o Bruno durante o run, para um PR no Agent-Skills depois dele. O foreman fica como observador de QA, e o proxy continua sendo chamado por ele.

1. **Notas do foreman em arquivo** (`.scratch/run-log/foreman-notes.md`): o que está nelas foi o que permitiu retomar depois do restart do Claude Code às 16:12.
2. **Observar por linha do run-log.md**, lendo o `.final` do estágio assim que a linha aparece. O check-in de 30 min passa a ser só heartbeat.

3. **O driver espera o reset do limite de uso e mantém a branch do estágio que perguntou,** em vez de apagá-la.

9 Recomendações

1. **Driver: manter a branch de um stage 2 que perguntou.** Os quatro commits fixados viraram retomadas de 5–11 min. Sem eles, cada ticket recomeçaria do zero (\$2,63 e 54 min de novo).
2. **Driver: esperar o reset do limite de uso** quando a mensagem traz o horário, sem gastar a parada de “API unreachable twice”.
3. **ticket-flow: reescrever “a test proves wrong after being committed”.** A regra fez 4 de 15 implementações pararem, e o proxy respondeu todas sem precisar do humano. Apoia-se na linha `gpt-6.1-sol high` do scoreboard (20 estágios, 4 perguntas, todas deste run). Um teste errado de harness pode ser corrigido num commit só de teste; parar deveria ficar para um teste que prova o contrato errado.
4. **ticket-flow: só o proxy escreve “Proxy decided”.** Dizer isso explicitamente no stage 2 (caso PHY-43).
5. **Manter `gpt-6.1-sol high` → `gpt-6.1-sol max`.** Apoia-se na linha `gpt-6.1-sol high` | `gpt-6.1-sol max` (16 revisões, 2 reabertas, ambas S2 implícito) e em \$1,39–1,42 por ticket nos dois runs.
6. **Stage 2: ao mudar um solver, testar o caso degenerado** (restrições redundantes, sistema singular). O PHY-41 estava a um cenário de duas cordas colineares.
7. **PHY-43: medir o pico após a retomada da tensão.** O proxy tirou do escopo o pico de 3157 N no passo 86 e pediu um ticket próprio se ele persistisse depois da correção. O probe da entrega cobriu só os passos 1–40, então ninguém conferiu. Fica para o stage 1.
8. **A fila acabou:** resta o CLEAN-13, à espera de triagem e stage 1.

10 Débito humano

Nenhuma linha **Débito humano**: nos dez tickets. No PR, a revisão humana fica para o PHY-39 (**Review: human**), além do PHY-30 (“Needs your call”) e do PHY-33, que já estavam lá desde runs anteriores.