

Sweatshop no PhysiSyst: cadeia da polia com massa e mola com massa

Sonnet 5.5 (high) no stage 2, GPT-6.1 Sol (max) no stage 3

Foreman, sessão `sweatshop/2026-10-01-1211`

1 de outubro de 2026

Resumo

Primeiro run do PhysiSyst com o Sonnet 5.5 como implementador, passado por `-Models 'stage 2 sonnet-5.5 high, stage 3 gpt-6.1-sol max'` (lineup *ad hoc*), a pedido do Bruno (“testar um novo implementador”). A fila eram PHY-45 e PHY-48, desbloqueados, e a cadeia PHY-49 → PHY-50 atrás do PHY-45. As revisões abriram CLEAN-20, 21 e 22, e o mesmo run os fechou.

- **Produzido:** 7 tickets mergeados na sessão nova, com **uma reabertura** (PHY-45). PR de sessão: #10, 7 linhas, todas **Review: agent** — Approve.
- **Custo: \$19,13** a preço de lista em 16 dos 21 estágios registrados (implementação \$13,95, revisão \$5,18); 5 linhas saíram com ?. 188 min de estágio, 34,0M tokens de entrada (95,9% em cache) e 273k de saída. \$2,73 por ticket mergeado.
- **O que deu errado:** o ambiente, não os modelos. O Codex CLI 0.156.1 recusava o `gpt-6.1-sol` com um 400 (“not supported when using Codex with a ChatGPT account”), que o driver leu como queda de API e parou; atualizar para 0.159.3 resolveu. Depois disso, duas paradas das tarefas da sessão mataram o driver no meio de um estágio, uma revisão estourou o teto de 20 min já pronta para mergear, e um teste antigo passou a estourar o timeout com a suíte em paralelo.
- **Veredito provisório:** o Sonnet 5.5 entregou 8 de 8 em **to-review**, sem falha nem pergunta, e foi o primeiro implementador a chamar o proxy sozinho para um critério impossível. Custa cerca de 3,5 vezes o Sol high por implementação (\$1,74 contra \$0,45–0,52). Com 8 revisões, o par é anedota.


1 Linha do tempo

12:11	Lançamento 1, driver 01489e8. Sessão nova <code>sweatshop/2026-10-01-1211</code> (o PR 9 já estava mergeado).
12:18	PHY-45 (aro da polia e direção guardada) em <code>to-review</code> em 6 min. A revisão falha duas vezes em 12 s com o 400 do Codex; o driver para com “API unreachable twice”.
12:24	O Bruno refaz o login; continua ChatGPT, e o teste do foreman ainda dá 400.
12:27	<code>codex update</code> de 0.156.1 para 0.159.3. Pelo Git Bash o instalador quebra (o <code>tar</code> do MSYS lê <code>C:</code> como host); pelo PowerShell passa. Um <code>codex exec</code> de teste responde.
12:28	Lançamento 2. A revisão do PHY-45 recebe “Selected model is at capacity” aos 13 min (12:42); o driver tenta de novo.
12:55	As tarefas da sessão são paradas (o Bruno ia desligar a internet). O driver morre a 13 min da segunda revisão, que estava reabrindo o PHY-45. As edições sem commit vão para <code>.scratch/run-log/PHY-45-review-killed-20261001-1255/</code> .
13:12	Lançamento 3. 13:28: PHY-45 reaberto (R1, salto de comprimento da corda), a mesma conclusão da revisão morta.
13:41	Passada 2 do PHY-45 em 13 min: o Sonnet chama o proxy, que reescreve o critério 2. 13:53: mergeado.
13:55	CLEAN-20 (ADR do aro) em 2 min; mergeado às 14:08.
14:15	PHY-48 (mola com massa no solve em grupo) em 7 min. A revisão estoura o teto de 20 min às 14:35, já pronta para o gate final e o merge; o driver estaciona o ticket como <code>blocked</code> .
14:38	PHY-49 (giro próprio do disco) em 3 min; mergeado às 14:50.
14:52	CLEAN-21 (ADR do giro integrado) em 2 min; mergeado às 15:00.
15:00	PHY-50 (ω do disco além do limite do Rapier) começa. Por volta de 15:13 as tarefas são paradas de novo; a tentativa morre com um commit vermelho e uma edição sem commit. O foreman guarda os dois e apaga a branch.
15:14	O foreman devolve o PHY-48 a <code>to-review</code> (sessão e branch do ticket) e relança com <code>-ReviewMinutes 40</code> . PHY-48 mergeado às 15:27, em 12 min.
15:36	PHY-50 em 8 min. A revisão bate no limite de uso do Codex às 15:44; o driver espera até 15:51 e mergeia às 16:05.
16:11	CLEAN-22 (ADR do contorno de ω) em 6 min; mergeado às 16:22. “Nothing runnable”; PR #10 atualizado às 16:23.

2 Métricas por estágio

Linhas 95–115 de `.scratch/run-log.md`. Minutos, tokens e custo como o driver gravou. As duas tentativas mortas pela parada das tarefas (revisão do PHY-45 às 12:55, implementação do PHY-50 às 15:13) não têm linha.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
P45 impl.	sonnet high	6	4,00 M	97 %	28 k	2,412	to-review
P45 revisão	sol max	0	?		?	?	erro 400
P45 revisão	sol max	0	?		?	?	erro 400
P45 revisão	sol max	14	?		?	?	sem capacidade
P45 revisão	sol max	15	1,70 M	95 %	16 k	0,670	reaberto
P45 impl. 2	sonnet high	13	2,80 M	94 %	58 k	4,396	to-review
P45 revisão 2	sol max	12	1,70 M	92 %	12 k	0,694	mergeado
C20 impl.	sonnet high	2	1,40 M	96 %	8 k	0,851	to-review
C20 revisão	sol max	13	1,50 M	95 %	10 k	0,552	mergeado
P48 impl.	sonnet high	7	5,50 M	98 %	41 k	2,803	to-review
P48 revisão	sol max	20	?		?	?	timeout
P49 impl.	sonnet high	3	2,10 M	97 %	11 k	1,053	to-review
P49 revisão	sol max	12	1,90 M	95 %	13 k	0,703	mergeado
C21 impl.	sonnet high	2	0,95 M	95 %	5 k	0,642	to-review
C21 revisão	sol max	8	0,86 M	90 %	10 k	0,425	mergeado
P48 revisão	sol max	13	2,10 M	96 %	13 k	0,708	mergeado
P50 impl.	sonnet high	8	2,20 M	98 %	10 k	1,053	to-review
P50 revisão	sol max	8	?		?	?	limite de uso
P50 revisão	sol max	15	2,40 M	95 %	18 k	0,864	mergeado
C22 impl.	sonnet high	6	1,40 M	97 %	7 k	0,741	to-review
C22 revisão	sol max	11	1,50 M	95 %	13 k	0,562	mergeado
Total		188	34,00 M	95,9 %	273 k	19,129	16 de 21 com preço
Implementação		47	20,35 M	96,8 %	168 k	13,951	8 estágios
Revisão		99	13,66 M	94,5 %	105 k	5,178	8 estágios com preço
Retrabalho		25	4,50 M		70 k	5,090	2 estágios (reabertura)
Perdido		42	?		?	?	5 linhas sem preço



Onde foi o custo. Por ticket: PHY-45 \$8,17 (46 min com preço, mais 14 perdidos e uma revisão morta), PHY-48 \$3,51 (20 min, mais 20 do timeout), PHY-50 \$1,92 (23 min, mais 8 do limite e uma tentativa morta), PHY-49 \$1,76, CLEAN-20 \$1,40, CLEAN-22 \$1,30, CLEAN-21 \$1,07. O estágio mais caro foi a passada 2 do PHY-45 (\$4,40, 13 min, 58 k de saída), que incluiu o proxy. A implementação levou 73 % do custo: o Sonnet 5.5 cobra \$1,74 por implementação, e o Sol max, \$0,65 por revisão. Os três CLEAN de documentação somaram \$3,77 e 42 min (20 % do run), cada um pagando um ciclo completo de estágio 2 e 3 para editar o ADR-0004.

O que se perdeu sem preço. 42 min em 5 linhas ?: dois 400 do CLI velho, uma falta de capacidade (14 min), o timeout do PHY-48 (20 min, com o trabalho pronto) e o limite de uso (8 min). Mais cerca de 26 min nas duas tentativas mortas, que não aparecem no log.

3 Comparação

Os runs anteriores do PhysiSyst com preço são de 30/09, todos com o par `gpt-6.1-sol`. A troca é só no implementador; o revisor é o mesmo.

	30/09 (lanç. 1–5)	30/09 (lanç. 6)	Este run
Implementador	sol high	sol high	sonnet-5.5 high
Estágios registrados	28	10	21
Tickets mergeados	10	2	7
Reaberturas	1	3	1
Implementação: falhou ou perguntou	4 de 15	0 de 5	0 de 8
Mediana da implementação	7 min	5 min	6 min
Custo médio por implementação	\$0,52	\$0,45	\$1,74
Mediana da revisão (com preço)	10 min	11 min	12,5 min
Custo médio por revisão	\$0,59	\$0,62	\$0,65
Estágios perdidos (?)	2	0	5
Custo registrado	\$14,20	\$5,39	\$19,13
Custo por ticket mergeado	\$1,42	\$2,69	\$2,73

A velocidade é a mesma; o preço da implementação é 3,4–3,9 vezes maior. O custo por ticket empata com o lançamento 6 porque lá o retrabalho do PHY-47 inflou a conta, e aqui não houve espiral. Três dos sete tickets eram só de documentação, o que puxa a mediana para baixo.

4 Atribuição das reaberturas

Uma reabertura no run: PHY-45, rodada 1, às 13:28. O revisor foi `gpt-6.1-sol max`, diferente do foreman (Opus 5.5), então o foreman classificou. Evidência: o ticket como o stage 2 o recebeu (`ce0b92c`), o diff revisado (`ecfac46...b6b61d8`) e a revisão (`9a23fd2`). A revisão morta às 12:55 tinha chegado ao mesmo R1, o que confirma o achado. Linhas em `.scratch/reopen-attribution.md`.

Ticket	Rodada	Rótulo	Achado e porquê
PHY-45	1	S1 ?	R1, critério 2: depois da tangente reta, a troca de direção salta o comprimento da corda de 6 para 7,287 m em 2µm de movimento. O teste novo comparava só uma pose depois da troca. O critério “segue a curva sem salto” era insatisfazível: os dois enrolamentos só têm o mesmo comprimento com as pontas e o centro colineares. O conserto pediu um Proxy <code>decided</code> que reescreveu o contrato, ou seja, uma decisão. Fica em dúvida porque o teste fraco era do stage 2.
PHY-45	1	S1	ADR-0004 ainda dizia que as polias só têm colliders no grupo 0 e atravessam corpos. O ADR não estava nos Primary files.
PHY-45	1	S2-implícito	<code>simulator.ts:813</code> ainda dizia “Mass 0 builds nothing”, desmentido pelo aro que o próprio stage 2 criou.
PHY-45	1	S2-implícito	<code>simulator.ts:1171</code> comparava a guarda nova ao ramo escalar <code>k <= 0</code> , que zera a tensão e retorna: comentário do próprio stage 2 descrevendo errado o código vizinho.
PHY-45	1	S1	O critério 4 cita 26 cenários e os passos 71/156; o critério 1 e o plano de testes autorizam 24. O stage 2 já tinha sinalizado a inconsistência no <code>.final</code> .

Totais: 3 S1 (um em dúvida), 2 S2-implícito, 0 S2-explícito, 0 S3. Os dois S2 são observações de comentário que a revisão não usou para reabrir (foram para o CLEAN-20). O motivo da reabertura foi o R1, rotulado S1. Mesmo assim, pela regra do scoreboard, a rodada conta como “reaberta por S2”. Sem *drip-feeding*: a revisão 2 não trouxe achado novo. Sem *churn*: a passada 2 seguiu a decisão do proxy, não um conselho da revisão.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (PhysiSyst, SIGAA-ME, SynchroNice, slip), depois de registrar a atribuição acima. O log do PhysiSyst desta máquina não tinha as linhas de 30/09, que estavam só na cópia `docs/run-log/run-log.md`. O scoreboard rodou sobre a união das duas (141 linhas, sem sobreposição), que é a cópia gravada neste run.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
sonnet	116	72	29	15	7m	?
claude-opus-5-5	35	31	4	0	6m	\$0.72 (1/35)
gpt-6.1-sol high	20	16	0	4	7m	\$10.02 (20/20)
sonnet-5.5 high	8	8	0	0	6m	\$13.95 (8/8)
fable	4	4	0	0	3m	?
gpt-6-luna	15	7	6	2	24m	?

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
sonnet	opus	65	19	29 %	0	≥0 %	19
?	opus	3	0	0 %	0	0 %	0
claude-opus-5-5	claude-fable-5-1	30	1	3 %	0	≥0 %	1
gpt-6.1-sol high	gpt-6.1-sol max	16	4	25 %	3	19 %	0
sonnet-5.5 high	gpt-6.1-sol max	8	1	12 %	1	12 %	0
sonnet	fable	1	0	0 %	0	0 %	0
fable	fable	3	0	0 %	0	0 %	0
gpt-6-luna	gpt-6-sol	7	3	43 %	0	≥0 %	3

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
gpt-6.1-sol high → gpt-6.1-sol max	5	2	0	6	1	0
sonnet-5.5 high → gpt-6.1-sol max	1	0	0	2	3	0
sonnet → opus	1	1	1	0	0	0

O que mudou desde o relatório anterior. O relatório de 30/09 rodou o scoreboard em outra população: incluía o EasyMath e as linhas de 30/09 do SynchroNice, que não estão nesta máquina, e não incluía o slip. As linhas não se comparam uma a uma. O que dá para afirmar:

- **Linha nova: sonnet-5.5 high → gpt-6.1-sol max**, 8 revisões, 1 reaberta, taxa S2 de 12 %, sem rótulo pendente.
- **gpt-6.1-sol high → gpt-6.1-sol max** aparece aqui com 16 revisões e 19 % (só PhysiSyst e o que o SynchroNice local tem). O relatório anterior mostrava 24 revisões e ≥17 % com o run paralelo do SynchroNice. A diferença é de população, não de desempenho.

Como ler.

- **Mesmo revisor, dois implementadores:** sob `gpt-6.1-sol max`, o Sol high tem taxa S2 de 19 % (16 revisões) e o Sonnet 5.5 high, 12 % (8 revisões). **O par do Sonnet está abaixo de 10 revisões: é anedota.**
- **Os 12 % do Sonnet são um teto, não um piso.** A única rodada conta como S2 por duas notas de comentário que não motivaram a reabertura; o achado que reabriu é S1. Contando só os achados que bloquearam, a taxa S2 seria 0 %.
- **3 S1 em uma rodada apontam para o stage 1** do PHY-45: um critério impossível, um arquivo que faltava nos Primary files e uma contagem inconsistente.

6 Observações sobre os modelos

Sonnet 5.5 (high), implementação

- **8 de 8 em to-review, sem falhar nem perguntar ao humano.** Mediana de 6 min, a mesma do Sol high.

- **Chamou o proxy por conta própria** no PHY-45 passada 2, quando viu que o critério 2 era insatisfazível. O proxy respondeu, e o Proxy **decided** ficou no ticket. É o uso certo do protocolo, ao contrário do Sol high no PHY-43, que escreveu ele mesmo essa linha.
- **.final honesto.** Sinalizou o desvio no critério 4 (PHY-45), o teste escrito depois do código no PHY-48 e o gate vermelho por causa de um teste lento e alheio no PHY-50 e no CLEAN-22. Nada foi escondido.
- **O mutate-verify achou um mutante sobrevivente** no PHY-48 (cortar a sensibilidade entre as pontas passava em todos os 146 testes) e fechou o buraco com um teste novo, num commit só de teste.
- **Teste fraco no ponto que reabriu:** no PHY-45 passada 1, a continuidade da troca de direção foi testada com uma pose só. Na passada 2, a amostragem ao longo da transição pegou o salto.
- **Caro:** \$1,74 por implementação, contra \$0,45–0,52 do Sol high. A passada 2 do PHY-45 sozinha custou \$4,40.

GPT-6.1 Sol (max), revisão

- **A reabertura veio com prova:** a função de produção importada direto no Node, a tabela de comprimento antes e depois da tangente e a asserção vermelha. A revisão morta às 12:55 tinha chegado ao mesmo número, de forma independente.
- **Repetiu as mutações registradas** em toda revisão de código e rodou o gate antes de cada merge.
- **Documentação vira ticket.** As três revisões de código abriram um CLEAN para atualizar o ADR-0004 em vez de corrigi-lo no estágio 3. Cada CLEAN pagou um ciclo inteiro: \$1,07–1,40 e 10–17 min.
- **Contornou o gate instável sem abrir ticket:** PHY-48, PHY-50 e CLEAN-22 mergearam com VITEST_MAX_WORKERS=1. A revisão confirmou que o timeout já existe na base, mas ninguém abriu um ticket para ele.
- **Revisões de 8–15 min, uma acima de 20** (PHY-48, a primeira). Nenhum S3.

7 Driver e runtime

- **CLI do Codex velho se passa por conta sem acesso.** O 0.156.1 não conhecia o gpt-6.1-sol (“Model metadata not found”) e o backend respondia 400 “not supported when using Codex with a ChatGPT account”. O driver tratou como queda de API e parou na segunda. O codex update resolveu, sem trocar o login.
- **codex update quebra no Git Bash:** o tar do MSYS lê C: como host remoto. Pelo PowerShell (System32\tar.exe) funciona.
- **O driver não tem pausa.** O Bruno pediu “pausar depois do merge, antes do próximo”; a única saída era matar o processo. As duas paradas das tarefas da sessão (12:55 e cerca de 15:13) mataram o driver no meio de um estágio, sem passar pelo **finally**. O foreman restaurou a árvore, guardou o trabalho e apagou a branch do PHY-50.
- **Teto de 20 min da revisão é curto para o Sol max** em ticket de física: o PHY-48 estourou pronto para mergear, e o driver jogou o estágio fora (o commit da revisão ficou na branch). Com `-ReviewMinutes 40`, a revisão seguinte levou 12 min.
- **Um teste estoura o timeout com a suíte em paralelo:** `simulator.test.ts` “a body launched beyond the viewport integrates indefinitely” leva cerca de 3,6s sozinho e 6,3s na suíte, acima dos 5s. O gate padrão ficou vermelho em pelo menos quatro estágios, todos contornados.
- **Falta de capacidade e limite de uso:** o driver tentou de novo e esperou o reset (15:44 até 15:51), como deveria.
- **Aviso inofensivo:** todo `.err` do Claude traz `claude-code:unrecognized_model` para `claude-sonnet-5-5`; os estágios rodaram normalmente.

- **Tectonic sumiu:** o binário que o Codex trazia em `~/codex/.tmp/.../latex/bin` não existia mais, provavelmente apagado pelo `codex update`. O relatório foi gravado primeiro só como `.tex`; com o aval do Bruno, o foreman baixou o Tectonic 0.17.0 do release oficial para o mesmo caminho e gerou o PDF.

8 Recomendações

1. **Driver: um 400 invalid_request_error não é queda de API.** Parar na primeira com a mensagem do backend, ou fazer no Preflight um `codex exec` de uma palavra por modelo do lineup. Teria poupado os 16 min entre 12:11 e 12:27.
2. **Driver: arquivo de pausa.** Um `.scratch/run-log/STOP` lido entre estágios, que encerra pelo `finally` normal. Foi o pedido do Bruno às 12:5x, e as duas mortes duras custaram cerca de 26 min de trabalho.
3. **Driver: ReviewMinutes padrão de 40 para revisores max.** Apoia-se nas revisões do Sol max: 8–15 min aqui, 19 no PHY-43 em 30/09 e mais de 20 no PHY-48.
4. **Abrir um CLEAN para o teste lento de simulator.test.ts,** com timeout próprio ou menos passos. Hoje o gate só passa porque cada revisão o contorna.
5. **ticket-flow: o estágio 3 corrige ADR e comentários desatualizados ele mesmo** quando o conserto é só documentação. Os três CLEAN do run custaram \$3,77 e 42 min (20 % do run) para editar um arquivo.
6. **Stage 1: incluir o ADR nos Primary files** quando a decisão do ticket muda um mecanismo que ele documenta, e conferir se cada critério numerado é satisfazível. Apoia-se nos 3 S1 da linha `sonnet-5.5 high` → `gpt-6.1-sol max` (1 rodada).
7. **Continuar testando o Sonnet 5.5 com o mesmo revisor** até passar de 10 revisões, antes de qualquer troca de lineup. Hoje a comparação com o Sol high (19 % com 16 contra 12 % com 8) é anedota pela regra.
8. **Foreman: não depender do .tmp do Codex para o LaTeX.** Uma atualização do Codex pode apagá-lo de novo; um Tectonic fora dele (no PATH) sobrevive.
9. **A fila acabou:** restam CLEAN-13, PHY-51 e PHY-52, todos `blocked` à espera do stage 1.

9 Débito humano

Nenhuma linha Débito humano: nos sete tickets. O PR #10 tem as sete linhas como **Review: agent** — Approve, sem “Needs your call”. Para o Bruno: mergear o PR #10 e rodar o stage 1 de CLEAN-13, PHY-51 e PHY-52. Fora do tracker: o teste lento (recomendação 4).