

Sweatshop no PhysiSyst: avisos do simulador, recusa no próprio corpo e corda solta da polia ideal

GPT-6.1 Sol (high) no stage 2, Sonnet 5.5 (xhigh) no hard, GPT-6.1 Sol (max) no stage 3

Foreman, sessão `sweatshop/2026-10-01-2342`

2 de outubro de 2026

Resumo

Run noturno com `-Models 'stage 2 gpt-6.1-sol high, hard sonnet-5.5 xhigh, stage 3 gpt-6.1-sol max'` (lineup *ad hoc*, o `Models (sol)` com o hard subido de high para xhigh), a pedido do Bruno: “seguir com os tickets restantes”. A fila eram CLEAN-24, PHY-51, PHY-52 e PHY-54 (`Difficulty: hard`), com o PHY-53 atrás do PHY-51.

- **Produzido:** 5 tickets mergeados, com **uma reabertura** (PHY-54, por fronteira de Primary files). PR de sessão: #12, 5 linhas, todas `Review: agent — Approve`.
- **Custo: \$15,32** a preço de lista em 12 dos 13 estágios registrados: `gpt-6.1-sol high` \$2,50 (4), `sonnet-5.5 xhigh` \$8,82 (2), `gpt-6.1-sol max` \$4,01 (6); uma linha saiu com ?. 128 min de estágio, 29,8 M tokens de entrada (95,2 % em cache) e 250 k de saída. \$3,06 por ticket mergeado.
- **O que deu errado:** o limite de uso do Codex. Às 00:45, 3 min dentro da revisão do PHY-53, o Codex respondeu “try again at 3:49 AM”. O driver esperou até 03:51, como deveria, mas o run ficou 3 h 06 parado: 58 % das 5 h 18 de relógio.
- **Veredito provisório:** o Sol high entregou 4 de 4 em `to-review`, sem reabrir, a \$0,62 por implementação. O Sonnet 5.5 xhigh resolveu o ticket mais difícil da fila e acertou a física de primeira, mas custou \$8,82 por um ticket e reabriu por escopo. Com 2 revisões, é anedota.


1 Linha do tempo

23:42	Lançamento único, driver 74dc512. Sessão nova <code>sweatshop/2026-10-01-2342</code> (o PR #11 já estava mergeado).
23:52	CLEAN-24 (recusa visível no clique no próprio corpo) em <code>to-review</code> em 9 min. 00:01: mergeado, sem achados.
00:09	PHY-51 (aviso do teto de ω do Rapier na API) em 8 min. 00:16: mergeado; a revisão só ajustou a ordem de comentários.
00:23	PHY-52 (residual zerado além do <code>ROPE_SLIP</code> na polia com massa) em 6 min. 00:32: mergeado, sem achados.
00:41	PHY-53 (avisos do simulador na tela) em 10 min.
00:45	A revisão do PHY-53 bate no limite de uso do Codex aos 3 min; o driver registra <code>api error, not counted</code> e espera até 03:51.
03:51	Revisão do PHY-53 recomeça. 04:03: mergeado, sem achados.
04:03	PHY-54 vai para o implementador hard (<code>sonnet-5.5 xhigh</code>). Em 19 min, <code>to-review</code> : a corda se solta da polia ideal em vez de enrolar uma volta.
04:40	PHY-54 reaberto em 18 min: os critérios passam, mas a guarda de <code>pieceLengths</code> e o bloco de testes estão fora dos Primary files. A revisão abre o CLEAN-25.
04:47	Passada 2 em 6 min. O próprio stage 2 chama o proxy, que amplia o Primary e cria o critério 6; os testes mudam de bloco num commit só de teste.
04:59	PHY-54 mergeado em 13 min. 05:00: “Nothing runnable”; PR #12 aberto.

2 Métricas por estágio

Linhas 116–128 de `.scratch/run-log.md`. Minutos, tokens e custo como o driver gravou.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
C24 impl.	sol high	9	2,40 M	97 %	8 k	0,694	to-review
C24 revisão	sol max	9	1,70 M	93 %	12 k	0,649	mergeado
P51 impl.	sol high	8	1,70 M	96 %	8 k	0,535	to-review
P51 revisão	sol max	6	0,89 M	93 %	9 k	0,385	mergeado
P52 impl.	sol high	6	1,20 M	90 %	8 k	0,560	to-review
P52 revisão	sol max	9	1,80 M	95 %	13 k	0,652	mergeado
P53 impl.	sol high	10	2,20 M	96 %	11 k	0,707	to-review
P53 revisão	sol max	3	?	?	?	?	limite de uso
P53 revisão	sol max	12	1,80 M	96 %	13 k	0,628	mergeado
P54 impl.	sonnet xhigh	19	8,10 M	96 %	110 k	6,058	to-review
P54 revisão	sol max	18	2,90 M	96 %	20 k	0,998	reaberto
P54 impl. 2	sonnet xhigh	6	3,30 M	95 %	25 k	2,757	to-review
P54 revisão 2	sol max	13	1,80 M	93 %	13 k	0,693	mergeado
Total		128	29,79 M	95,2 %	250 k	15,316	12 de 13 com preço
Implementação		58	18,90 M	95,6 %	170 k	11,311	6 estágios
Revisão		70	10,89 M	94,6 %	80 k	4,005	6 estágios com preço
Retrabalho		19	5,10 M		38 k	3,450	2 estágios (reabertura)
Perdido		3	?		?	?	1 linha sem preço



Onde foi o custo. Por ticket: PHY-54 \$10,51 (56 min), CLEAN-24 \$1,34, PHY-53 \$1,34 (mais 3 min perdidos), PHY-52 \$1,21, PHY-51 \$0,92. O PHY-54 levou 69 % do custo do run; só a primeira implementação (\$6,06, 110k de saída) custou mais que os outros quatro tickets juntos (\$4,81). O Sol high cobra \$0,62 por implementação; o Sonnet 5.5 xhigh, \$4,41; o Sol max, \$0,67 por revisão.

O que se perdeu. Em tokens, quase nada: uma linha ? de 3 min. Em relógio, 3 h 06 de espera pelo reset do Codex (00:45–03:51). O limite chegou depois de 7 estágios Codex completos e 11,9 M tokens de entrada desde 23:42.

3 Comparação

Os runs anteriores do PhysiSyst com preço, todos com `gpt-6.1-sol max` na revisão.

	30/09 (1–5)	30/09 (6)	01/10	Este run
Implementador	sol high	sol high	sonnet-5.5 high	sol high + sonnet xhigh
Estágios registrados	28	10	21	13
Tickets mergeados	10	2	7	5
Reaberturas	1	3	1	1
Implementação: falhou ou perguntou	4 de 15	0 de 5	0 de 8	0 de 6
Mediana da implementação	7 min	5 min	6 min	8,5 min
Custo médio por implementação	\$0,52	\$0,45	\$1,74	\$1,89
só Sol high	\$0,52	\$0,45	—	\$0,62
Mediana da revisão (com preço)	10 min	11 min	12,5 min	10,5 min
Custo médio por revisão	\$0,59	\$0,62	\$0,65	\$0,67
Estágios perdidos (?)	2	0	5	1
Custo registrado	\$14,20	\$5,39	\$19,13	\$15,32
Custo por ticket mergeado	\$1,42	\$2,69	\$2,73	\$3,06

Sem o PHY-54, o run custaria \$4,81 por 4 tickets (\$1,20 cada), o melhor número do PhysiSyst até aqui. O Sol high ficou um pouco mais caro que em 30/09 (\$0,62 contra \$0,45–0,52) com tickets de UI e física um pouco maiores. O gate passou em todos os estágios sem `VITEST_MAX_WORKERS=1`: o CLEAN-23 (PR #11) resolveu o teste lento que o relatório anterior apontava.

4 Atribuição das reaberturas

Uma reabertura no run: PHY-54, rodada 1, às 04:40. O revisor foi `gpt-6.1-sol max`, diferente do foreman (Opus 5.5), então o foreman classificou. Evidência: o ticket como o stage 2 o recebeu (14e3373, o mesmo da base da sessão), o diff revisado (f2f6d62...497fc6f) e a revisão (a552a99). Linhas em `.scratch/reopen-attribution.md`.

Ticket	Rodada	Rótulo	Achado e porquê
PHY-54	1	S1	A guarda <code>Math.max(0, ...)</code> em <code>pieceLengths</code> está fora dos Primary files de <code>simulator.ts</code> , embora a própria revisão a julgue necessária. O stage 1 já sabia que <code>pieceLengths</code> soma a varredura negativa, mas mandou só a corda mista para o PHY-55 e esqueceu a corda ideal em grupo. O conserto pediu um Proxy <code>decided</code> que ampliou o Primary e criou o critério 6.
PHY-54	1	S2-expl./código ?	Os cinco testes novos de <code>ropePath</code> estão num <code>describe</code> próprio, fora do bloco nomeado nos Primary files. O bloco está escrito no ticket, e mover não pediu decisão. Fica em dúvida porque é de lugar, não de comportamento, e beira o S3.
PHY-54	1	S2-implícito	<code>wrapAngle</code> de <code>ropePath.ts</code> repete a fórmula de <code>simulator.ts</code> . Duplicação do próprio stage 2, que a sinalizou e deixou; não bloqueou.
PHY-54	1	S1	Duas polias soltas com projeções em ordem inversa à de <code>via</code> dão 21 m e puxões $(\mp 2, 0)$ em vez da perna reta de 11 m. Caso fora da regra das várias polias que o proxy fixou; vira o CLEAN-25 e não bloqueou.

Totais: 2 S1, 1 S2-explicito/código (em dúvida), 1 S2-implícito, 0 S3. O motivo real da reabertura foi o primeiro achado (S1); o segundo veio de carona. Pela regra do scoreboard a rodada conta como “reaberta por S2” por causa do segundo e do terceiro. Sem *drip-feeding*: a revisão 2 não trouxe achado novo. Sem *churn*: a passada 2 não mexeu no código de produção.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (PhysiSyst, SIGAA-ME, SynchroNice, slip), depois de registrar a atribuição acima. Para o PhysiSyst, o scoreboard rodou sobre a cópia `docs/run-log/run-log.md` com as 13 linhas deste run (154 linhas): o log local ainda não tem as 38 linhas de 30/09 da outra máquina. Nenhum dos dois logs tem as linhas do CLEAN-23 (PR #11).

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
sonnet	121	75	31	15	7m	\$10.53 (4/121)
claude-opus-5-5	35	31	4	0	6m	\$0.72 (1/35)
gpt-6.1-sol high	33	29	0	4	8m	\$23.85 (33/33)
sonnet-5.5 high	8	8	0	0	6m	\$13.95 (8/8)
sonnet-5.5 xhigh	2	2	0	0	19m	\$8.82 (2/2)
fable	5	5	0	0	3m	?
gpt-6-luna	23	11	10	2	26m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet-5 xhigh	11	6	2	3	8m	\$18.09 (11/11)
gpt-6-astra low	2	2	0	0	30m	\$19.03 (2/2)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
sonnet	opus	68	20	29 %	1	≥ 1 %	19
?	opus	4	0	0 %	0	0 %	0
claude-opus-5-5	claude-fable-5-1	30	1	3 %	0	≥ 0 %	1
gpt-6.1-sol high	gpt-6.1-sol max	28	7	25 %	6	21 %	0
sonnet-5.5 high	gpt-6.1-sol max	8	1	12 %	1	12 %	0
sonnet-5.5 xhigh	gpt-6.1-sol max	2	1	50 %	1	50 %	0
sonnet	fable	1	0	0 %	0	0 %	0
fable	fable	4	1	25 %	0	≥ 0 %	1
gpt-6-luna	gpt-6-sol	11	7	64 %	0	≥ 0 %	7
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥ 0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥ 0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥ 0 %	5
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0
gpt-6-astra low	gpt-6.1-sol max	2	1	50 %	1	50 %	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
gpt-6.1-sol high → gpt-6.1-sol max	7	3	0	7	1	0
sonnet-5.5 high → gpt-6.1-sol max	1	0	0	2	3	0
sonnet-5.5 xhigh → gpt-6.1-sol max	1	1	0	1	2	0
sonnet → opus	1	1	1	0	0	0
gpt-6-astra low → gpt-6.1-sol max	1	2	0	1	0	0

O que mudou desde o relatório anterior.

- **Linha nova: sonnet-5.5 xhigh → gpt-6.1-sol max**, 2 revisões, 1 reaberta, taxa S2 de 50 %. É deste run.
- **gpt-6.1-sol high → gpt-6.1-sol max** foi de 16 revisões e 19 % para 28 e 21 %. Este run soma 4 revisões sem reabertura; as outras 8 revisões e as 3 reaberturas novas vieram dos repositórios irmãos desde 01/10.
- **Linhas novas dos irmãos: gpt-6-astra, gpt-6-sol, gpt-5.6-sol, sonnet-5 xhigh e gpt-6-astra low.** sonnet → opus ganhou 3 revisões e uma reabertura classificada como S2. Nenhuma delas é deste run.

Como ler.

- **Mesmo revisor, três implementadores:** sob gpt-6.1-sol max, o Sol high tem taxa S2 de 21 % (28 revisões), o Sonnet 5.5 high 12 % (8) e o Sonnet 5.5 xhigh 50 % (2). **Os dois pares do Sonnet estão abaixo de 10 revisões: são anedota.** O xhigh rodou um único ticket, o hard da fila.
- **Os 50 % do xhigh superestimam o implementador.** A rodada conta como S2 por um achado de lugar dos testes (em dúvida) e por uma duplicação que não bloqueou; o achado que reabriu é S1. Contando só os achados que bloquearam, a taxa continua em 50 % só por causa do segundo achado, que é S2 em dúvida.
- **5 S1 em 2 rodadas do Sonnet 5.5** apontam para o stage 1 dos tickets que ele recebeu, PHY-45 e PHY-54, não para o implementador.

6 Observações sobre os modelos

GPT-6.1 Sol (high), implementação

- **4 de 4 em to-review, 4 de 4 mergeados de primeira.** 6–10 min, \$0,54–0,71.
- **Mutate-verify por teste, com a saída vermelha copiada no ticket** em todos os quatro, inclusive nos testes de DOM do CLEAN-24 e do PHY-53, como o AGENTS.md exige.
- **No PHY-53, 3 dos 5 testes passaram na primeira execução** (ordem, ausência, limpeza): eram caracterização do comportamento que a primeira fatia já trazia. A prova veio das muta-

ções, e o `.final` disse isso. O harness foi corrigido depois do commit de testes, com o vermelho repetido. A revisão aceitou.

- **Respeitou o escopo:** deixou a exibição do aviso para o PHY-53 no PHY-51, como o ticket mandava, e registrou a limitação do limiar de 1 cm no PHY-52, prevista pelo ticket.

Sonnet 5.5 (xhigh), implementação hard

- **A física saiu certa na primeira passada.** Os 11 cenários de energia, a volta acima de 2π e as duas polias passaram; a revisão repetiu o vermelho (16 testes) e as cinco mutações.
- **Achou um defeito que o ticket não previa:** sem o clamp, uma corda ideal em grupo esticava de 7,66 para 8,30 m. Escreveu o teste, provou com mutação e corrigiu, mas fora dos Primary files. Foi isso que reabriu.
- **Na passada 2, chamou o proxy por conta própria** para ampliar o contrato, em vez de remover a guarda ou escrever o `Proxy decided` ele mesmo. É o segundo run seguido em que o Sonnet 5.5 faz isso.
- **Caro:** \$6,06 e 110 k de saída na passada 1, 9,8 vezes uma implementação do Sol high no mesmo run. Não dá para separar o efeito do xhigh do efeito do ticket: foi o único hard.

GPT-6.1 Sol (max), revisão

- **Repetiu vermelho e mutações em todas as seis revisões** e rodou o gate completo antes de cada merge.
- **Reabriu o PHY-54 pela regra, não pelo mérito:** escreveu que a guarda era necessária e que os critérios passavam, e mesmo assim devolveu, citando o `ticket-flow`. O ciclo extra custou \$3,45 e 19 min para nenhuma linha de produção.
- **Achou um caso que ninguém pediu** (CLEAN-25, projeções invertidas), reproduzido com o código de produção, e o tirou do contrato em vez de reabrir por ele.
- **Nenhum CLEAN de documentação neste run**, ao contrário do anterior. A revisão do PHY-51 ajustou ela mesma a ordem de comentários.

7 Driver e runtime

- **Limite de uso do Codex:** 00:45, “try again at 3:49 AM”. O driver esperou até 03:51 e retomou sozinho, sem gastar tentativa. É o segundo run seguido com esse limite (o anterior às 15:44), e este custou 3 h 06 de relógio.
- **As recomendações do relatório anterior já estão no driver:** teto de revisão de 40 min, arquivo STOP e parada imediata num 400. Nenhuma foi exercitada neste run: a revisão mais longa levou 18 min.
- **Gate estável:** nenhum estágio precisou de `VITEST_MAX_WORKERS=1`.
- **Aviso inofensivo de novo:** o `.err` do Claude traz `claude-code:unrecognized_model` para `claude-sonnet-5-5`; o estágio rodou normalmente. Os do Codex trazem “failed to refresh available models: request timed out”, sem efeito.
- **Log local incompleto:** `.scratch/run-log.md` desta máquina não tem as 38 linhas de 30/09, e nenhum log tem o CLEAN-23. A cópia em `docs/run-log/` é a mais completa.

8 Recomendações

1. **Stage 1: quando o proxy corta o escopo, listar nos Primary files toda função que o corte toca.** O PHY-54 nomeava `pieceLengths` no texto, mas não no Primary. Apoia-se nos 5 S1 das linhas `sonnet-5.5 high` e `sonnet-5.5 xhigh` → `gpt-6.1-sol max` (1 rodada cada; anedota).

2. **ticket-flow:** o stage 3 pode consultar o proxy antes de reabrir só por fronteira, quando ele mesmo julga o código fora da fronteira necessário. O proxy deu a resposta em minutos na passada 2; a reabertura custou \$3,45 e 19 min a mais.
3. **Primary files:** nomear o arquivo de teste, não o **describe**. Um bloco de testes no lugar errado foi o segundo motivo da reabertura do PHY-54, sem efeito em comportamento.
4. **Codex:** contar com cerca de 7–8 estágios por janela do plano atual em runs longos. Os dois últimos runs bateram no limite depois de poucas horas; um lineup com o implementador no Claude dividiria a carga.
5. **Sonnet 5.5 xhigh no hard:** manter só se o próximo hard confirmar. Hoje há 2 revisões, e o custo (\$8,82 por ticket) é 7 vezes o de um ticket do Sol high (\$1,20). A recomendação não se apoia no scoreboard; o par tem 2 revisões.
6. **Abrir um CLEAN para o wrapAngle duplicado** (`ropePath.ts` e `simulator.ts`). O stage 2 e a revisão o anotaram, mas nenhum ticket existe.
7. **A fila acabou:** restam CLEAN-25, PHY-55 e PHY-56, todos **blocked** à espera do stage 1.

9 Débito humano

Nenhuma linha Débito humano: nos cinco tickets. O PR #12 tem as cinco linhas como **Review: agent** — Approve, sem “Needs your call”. Para o Bruno: mergear o PR #12, rodar o stage 1 de CLEAN-25, PHY-55 e PHY-56, e decidir sobre o CLEAN do `wrapAngle` (recomendação 6).