

Sweatshop no PhysiSyst: corda solta da polia com massa, desenho e clique no caminho simulado

Sonnet 5.5 (high, hard xhigh) no stage 2, Opus 5.5 (xhigh) no stage 3

Foreman, sessão `sweatshop/2026-10-02-1156`

2 de outubro de 2026

Resumo

Run diurno em dois lançamentos na mesma sessão. O primeiro (11:56) usou o lineup padrão de então, `Models`: com `claude-opus-5-5 high` no stage 2 e `claude-fable-5-1 high` no stage 3. Às 12:08 o Bruno pediu para parar depois do estágio corrente e trocar o lineup. O driver parou pelo arquivo `STOP` às 12:13 e foi relançado às 12:15 com `-Models 'stage 2 sonnet-5.5 high, hard sonnet-5.5 xhigh, stage 3 opus-5.5 xhigh'`, só para este run. No mesmo intervalo o `Models`: do `AGENTS.md` virou `gpt-6.1-sol high, hard sonnet-5.5 xhigh, gpt-6.1-sol max` (1948857 na main, f42a2c9 na sessão); o antigo ficou como `Models (opus)`.

- **Produzido:** 6 tickets mergeados, **nenhuma reabertura:** `CLEAN-26`, `CLEAN-25`, `PHY-56`, `CLEAN-27`, `PHY-55` (`Difficulty: hard`) e `PHY-57`. A fila esvaziou. PR de sessão: #13, 6 linhas, todas `Review: agent — Approve`.
- **Custo: \$31,40** a preço de lista nos 12 estágios, todos com preço: `claude-opus-5-5 high` \$2,31 (2), `claude-fable-5-1 high` \$1,73 (1), `sonnet-5.5 high` \$6,46 (3), `sonnet-5.5 xhigh` \$3,63 (1), `opus-5.5 xhigh` \$17,27 (5). 84 min de estágio, 48,7 M tokens de entrada (95,8 % em cache) e 372 k de saída. \$5,23 por ticket mergeado.
- **O que deu errado:** nada quebrou. O ponto fraco é de medida: a revisão do Opus 5.5 xhigh fechou sozinha, em 4 de 5 tickets, lacunas que outro revisor teria devolvido (um teste faltando no `CLEAN-27`, o vermelho isolado do critério 4.3 no `PHY-56`). O scoreboard registra 0 reaberturas e não vê esses achados.
- **Veredito provisório:** lineup caro e sem atrito. A revisão custou \$3,45 em média, 5 vezes a do Sol max (\$0,67 no run anterior), e levou 61 % do custo do run. O Sonnet 5.5 entregou 4 de 4 em `to-review` de primeira. Com 3 e 1 revisões nos pares novos, é anedota.


1 Linha do tempo

11:56	Lançamento 1, driver 74dc512, lineup padrão. Sessão nova <code>sweatshop/2026-10-02-1156</code> (o PR #12 já estava mergeado).
12:01	CLEAN-26 (um <code>wrapAngle</code> exportado em <code>ropePath</code>) em <code>to-review</code> em 4 min. 12:04: mergeado pelo Fable, sem achados.
12:08	O Bruno pede parada depois do estágio corrente e novo lineup; STOP criado com o CLEAN-25 em implementação.
12:13	CLEAN-25 (junções das polias soltas igualmente espaçadas) em <code>to-review</code> em 9 min. O driver acha o STOP, publica o PR #13 com 1 ticket e volta à <code>main</code> .
12:15	Lineup padrão trocado no <code>AGENTS.md</code> ; lançamento 2 com <code>-Models</code> . A <code>main</code> tinha 4 commits do stage 1 sem push, que subiram junto.
12:22	CLEAN-25 mergeado pelo Opus 5.5 xhigh em 7 min.
12:33	PHY-56 (desenho da corda pelo caminho simulado) em 11 min. 12:43: mergeado; a revisão isolou o vermelho do critério 4.3.
12:47	CLEAN-27 (clique na corda pelo caminho simulado) em 3 min. 12:53: mergeado; a revisão acrescentou o clique antes do primeiro passo.
13:03	PHY-55 (corda se solta da polia com massa) vai para o hard (<code>sonnet-5.5 xhigh</code>): 78 testes vermelhos, <code>to-review</code> em 10 min. 13:11: mergeado.
13:14	PHY-57 (corda volta a prender no disco) em 3 min. 13:23: mergeado.
13:24	“Nothing runnable”; PR #13 atualizado com 6 tickets.

2 Métricas por estágio

Linhas 129–140 de `.scratch/run-log.md`. Minutos, tokens e custo como o driver gravou.

Estágio	Modelo	Min	Entrada	Cache	Saída	Custo	Desfecho
C26 impl.	opus-5-5 high	4	1,00 M	93 %	5 k	0,907	to-review
C26 revisão	fable-5-1 high	3	0,91 M	93 %	4 k	1,734	mergeado
C25 impl.	opus-5-5 high	9	2,60 M	97 %	16 k	1,402	to-review
C25 revisão	opus xhigh	7	5,50 M	96 %	37 k	3,186	mergeado
P56 impl.	sonnet high	11	6,60 M	96 %	47 k	4,158	to-review
P56 revisão	opus xhigh	10	5,10 M	95 %	48 k	3,488	mergeado
C27 impl.	sonnet high	3	2,40 M	97 %	11 k	1,164	to-review
C27 revisão	opus xhigh	6	4,20 M	96 %	35 k	2,631	mergeado
P55 impl.	sonnet xhigh	10	5,90 M	97 %	52 k	3,628	to-review
P55 revisão	opus xhigh	9	7,20 M	96 %	53 k	4,069	mergeado
P57 impl.	sonnet high	3	2,10 M	97 %	12 k	1,142	to-review
P57 revisão	opus xhigh	9	5,20 M	94 %	52 k	3,893	mergeado
Total		84	48,71 M	95,8 %	372 k	31,402	12 de 12 com preço
Implementação		40	20,60 M	96,5 %	143 k	12,401	6 estágios
Revisão		44	28,11 M	95,4 %	229 k	19,001	6 estágios
Retrabalho		0	—	—	—	0	nenhuma reabertura
Perdido		0	—	—	—	0	nenhuma linha ?



Onde foi o custo. Por ticket: PHY-55 \$7,70 (19 min), PHY-56 \$7,65 (21 min), PHY-57 \$5,04, CLEAN-25 \$4,59, CLEAN-27 \$3,80, CLEAN-26 \$2,64. Pela primeira vez no PhysiSyst a revisão custou mais que a implementação: \$19,00 contra \$12,40, 58 % da entrada e 61 % do custo. Em 4 dos 5 tickets revisados pelo Opus 5.5 xhigh a revisão custou mais que a implementação; no PHY-57, 3,4 vezes. Até o Fable 5.1 high, no CLEAN-26, custou \$1,73 contra \$0,91 do Opus que implementou.

O que se perdeu. Nada em tokens: nenhuma reabertura, nenhuma linha ?. Em relógio, cerca de 2 min entre o STOP (12:13:35) e o primeiro estágio do lançamento 2 (12:15:35). Relógio total: 88 min, de 11:56 a 13:24.

3 Comparação

Os runs anteriores do PhysiSyst com preço. Os quatro primeiros revisaram com `gpt-6.1-sol max`; este, com Fable 5.1 high (1) e Opus 5.5 xhigh (5).

	30/09 (1-5)	30/09 (6)	01/10	02/10 noite	Este run
Implementador	sol high	sol high	sonnet high	sol + sonnet xh	opus + sonnet
Estágios registrados	28	10	21	13	12
Tickets mergeados	10	2	7	5	6
Reaberturas	1	3	1	1	0
Impl.: falhou ou perguntou	4 de 15	0 de 5	0 de 8	0 de 6	0 de 6
Mediana da implementação	7 min	5 min	6 min	8,5 min	6,5 min
Custo médio por impl.	\$0,52	\$0,45	\$1,74	\$1,89	\$2,07
Mediana da revisão	10 min	11 min	12,5 min	10,5 min	8 min
Custo médio por revisão	\$0,59	\$0,62	\$0,65	\$0,67	\$3,17
Estágios perdidos (?)	2	0	5	1	0
Custo registrado	\$14,20	\$5,39	\$19,13	\$15,32	\$31,40
Custo por ticket mergeado	\$1,42	\$2,69	\$2,73	\$3,06	\$5,23

O custo por ticket quase dobrou em relação ao run da noite, e a diferença é quase toda da revisão: com a média de revisão do Sol max (\$0,67), este run teria custado cerca de 16,42, ou 2,74 por ticket. O Sonnet 5.5 high saiu a \$2,15 por implementação, perto dos \$1,74 de 01/10. O Sonnet 5.5 xhigh fez o hard do run por \$3,63, contra \$8,82 do PHY-54 na noite, mas o PHY-55 chegou mais mastigado: o proxy tinha fixado 9 decisões no stage 1.

4 Atribuição das reaberturas

Nenhuma rodada `reopened` neste run, logo nenhuma linha nova em `.scratch/reopen-attribution.md`. Sem *drip-feeding* e sem *churn*.

Três achados que a revisão consertou em vez de devolver teriam rótulo se tivessem reaberto. O foreman os anota aqui sem registrar linha, porque o arquivo só conta rodadas reabertas:

Ticket	Rótulo provável	Achado consertado na revisão
CLEAN-27	S2-explicito/teste	O teste de App nunca clicava antes do primeiro passo, então metade do critério 3.2 não tinha prova. A revisão acrescentou o clique (9f95310) e registrou duas mutações.
PHY-56	S2-explicito/teste ?	O critério 4.3 não tinha vermelho próprio: no teste compartilhado, a mutação 3 parava no 4.1. A revisão isolou e viu o vermelho, sem commit de teste.
PHY-57	S2-explicito/código ?	O critério 4 pedia que o comentário de <code>Grip.loose</code> dissesse como o impacto é absorvido; só o ADR dizia. A revisão corrigiu (42937d2).

Os três são do Sonnet 5.5 high. Contados como reabertura, o par `sonnet-5.5 high` → `opus-5.5 xhigh` teria 2 ou 3 de 3, não 0 de 3.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre os quatro repositórios desta máquina com `.scratch/run-log.md` (PhysiSyst, SIGAA-ME, SynchroNice, slip). Para o PhysiSyst, rodou sobre `docs/run-log/run-log.md` com as 12 linhas deste run acrescentadas (178 linhas): o log local continua sem as linhas de 30/09 da outra máquina.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
sonnet	121	75	31	15	7m	\$10.53 (4/121)
claude-opus-5-5	35	31	4	0	6m	\$0.72 (1/35)
gpt-6.1-sol high	35	31	0	4	9m	\$27.53 (35/35)
sonnet-5.5 high	11	11	0	0	6m	\$20.42 (11/11)
sonnet-5.5 xhigh	3	3	0	0	10m	\$12.44 (3/3)
claude-opus-5-5 high	2	2	0	0	9m	\$2.31 (2/2)
fable	5	5	0	0	3m	?
gpt-6-luna	23	11	10	2	26m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet-5 xhigh	11	6	2	3	8m	\$18.09 (11/11)
gpt-6-astra low	2	2	0	0	30m	\$19.03 (2/2)
gpt-6.1-sol max	3	1	2	0	17m	\$1.44 (1/3)

Implementador	Revisor	Reviews	Reabertos	Taxa	Por S2	Taxa S2	Sem rótulo
sonnet	opus	68	20	29 %	1	≥1 %	19
?	opus	4	0	0 %	0	0 %	0
claude-opus-5-5	claude-fable-5-1	30	1	3 %	0	≥0 %	1
gpt-6.1-sol high	gpt-6.1-sol max	30	8	27 %	6	≥20 %	1
sonnet-5.5 high	gpt-6.1-sol max	8	1	12 %	1	12 %	0
sonnet-5.5 xhigh	gpt-6.1-sol max	2	1	50 %	1	50 %	0
claude-opus-5-5 high	claude-fable-5-1 high	1	0	0 %	0	0 %	0
claude-opus-5-5 high	opus-5.5 xhigh	1	0	0 %	0	0 %	0
sonnet-5.5 high	opus-5.5 xhigh	3	0	0 %	0	0 %	0
sonnet-5.5 xhigh	opus-5.5 xhigh	1	0	0 %	0	0 %	0
sonnet	fable	1	0	0 %	0	0 %	0
fable	fable	4	1	25 %	0	≥0 %	1
gpt-6-luna	gpt-6-sol	11	7	64 %	0	≥0 %	7
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0
gpt-6-astra low	gpt-6.1-sol max	2	1	50 %	1	50 %	0
gpt-6.1-sol max	gpt-6.1-sol max	1	1	100 %	0	≥0 %	1

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
gpt-6.1-sol high → gpt-6.1-sol max	7	3	0	7	1	0
sonnet-5.5 high → gpt-6.1-sol max	1	0	0	2	3	0
sonnet-5.5 xhigh → gpt-6.1-sol max	1	1	0	1	2	0
sonnet → opus	1	1	1	0	0	0
gpt-6-astra low → gpt-6.1-sol max	1	2	0	1	0	0

O que mudou desde o relatório anterior.

- **Quatro pares novos, todos deste run e todos com 0 reaberturas:** sonnet-5.5 high → opus-5.5 xhigh (3), sonnet-5.5 xhigh → opus-5.5 xhigh (1), claude-opus-5-5 high → claude-fable-5-1 high (1) e claude-opus-5-5 high → opus-5.5 xhigh (1).
- **sonnet-5.5 high** foi de 8 para 11 estágios e **sonnet-5.5 xhigh** de 2 para 3 (mediana de 19 para 10 min). **claude-opus-5-5 high** é linha nova, separada de **claude-opus-5-5** sem esforço.
- **gpt-6.1-sol high** → **gpt-6.1-sol max** foi de 28 revisões e 21 % de taxa S2 para 30 e $\geq 20\%$, com uma reabertura sem rótulo. **gpt-6.1-sol max** apareceu como implementador (3 estágios, 2 falhas) com um par **gpt-6.1-sol max** → **gpt-6.1-sol max** reaberto e sem rótulo. Nada disso é deste run: vem dos repositórios irmãos.

Como ler.

- **Mesmo implementador, dois revisores:** o Sonnet 5.5 high tem 12% de reabertura sob o Sol max (8 revisões) e 0% sob o Opus 5.5 xhigh (3). **Ambos abaixo de 10 revisões: anedota.** E o 0% é do revisor, não do implementador: a seção anterior mostra que o Opus consertou o que o Sol max teria devolvido.
- **Os pares do Opus 5.5 xhigh com 0%** somam 10 revisões entre sonnet-5 xhigh, sonnet-5.5 high, sonnet-5.5 xhigh e claude-opus-5-5 high, nenhuma reaberta. Juntos, sugerem um revisor que conserta em vez de devolver; separados, cada par é anedota.
- **Nenhum rótulo novo:** a tabela de achados não mudou. Os Sem rótulo novos são dos irmãos.

6 Observações sobre os modelos

Opus 5.5 (high), implementação (lançamento 1)

- **2 de 2 em to-review, 2 de 2 mergeados.** CLEAN-26 em 4 min (\$0,91), CLEAN-25 em 9 min (\$1,40).
- **Registro de mutação completo** no CLEAN-25, inclusive a mutação de integração nos dois cenários de aceitação.
- **Dois deslizos admitidos no próprio .final:** o to-review entrou num commit de docs separado, e o vermelho do critério 1 nunca mostra os 21 m previstos porque o teste de caminhada para na primeira falha. Ergueu o timeout desse teste para 30s num commit só de teste e repetiu o vermelho.

Sonnet 5.5 (high), implementação

- **3 de 3 em to-review, 3 de 3 mergeados.** PHY-56 em 11 min (\$4,16), CLEAN-27 e PHY-57 em 3 min (\$1,16 e \$1,14).
- **Harness errado no commit vermelho do PHY-56:** um teste nunca poderia passar e outro deixava uma mutação viva. Ambos foram corrigidos em commits só de teste, com as cinco mutações repetidas. É o mesmo padrão do PHY-53 do Sol high na noite.
- **Três lacunas de prova,** todas fechadas pela revisão (seção 4). Nenhuma de comportamento.
- **PHY-57: o primeiro commit de código deixou o Stage: em implementing;** um commit seguinte o corrigiu. Admitido no .final.

Sonnet 5.5 (xhigh), implementação hard

- **PHY-55 em 10 min, \$3,63, 78 de 78 vermelhos** no commit de testes (+231 J no caso 1/1 com $v_x = 8$ antes do conserto).
- **Registrou e não investigou** a divergência entre as faixas de energia da mutação 1 e as do ticket (até +189 kJ contra +45,9 kJ previstos). A revisão explicou: o conserto também solta no `correctPieces`, o que o protótipo provavelmente não fazia.
- **Mais barato que no PHY-54** (\$3,63 contra \$8,82 com a reabertura), num ticket com 9 decisões do proxy já no stage 1.

Fable 5.1 (high), revisão (lançamento 1)

- **Uma revisão, CLEAN-26, 3 min, \$1,73:** sem achados, vermelho reproduzido (1 de 21). Custou 1,9 vez a implementação de um refactor de uma função.

Opus 5.5 (xhigh), revisão

- **5 de 5 mergeados, 6–10 min, \$2,63–4,07.** Repetiu o vermelho e as mutações em todos e rodou o gate antes de cada merge.
- **Conserta em vez de devolver.** CLEAN-27: escreveu o teste que faltava e duas mutações. PHY-56: isolou o vermelho do 4.3. PHY-55: explicou a divergência da mutação 1 e refluíu dois comentários que só passavam no `git grep` do critério 6 pela quebra de linha. PHY-57: cumpriu o critério 4, tirou uma linha morta e evitou recalculas as peças a cada passo.
- **Anota sem abrir ticket:** a busca “caminho do simulador, senão o do documento” em três arquivos (`draw.ts`, `overlay.ts`, `hitTest.ts`), `drawScene` com 8 argumentos posicionais, três regras do CLEAN-25 sem teste.
- **Caro:** 45 k de saída em média por revisão, contra 13 k do Sol max na noite.

7 Driver e runtime

- **STOP funcionou como prometido:** achado às 12:13:35, entre estágios, com o PR publicado e a árvore na `main`. Foi o primeiro uso real; custou cerca de 2 min.
- **Mesmo modelo, duas grafias:** a binding escreve `claude-opus-5-5` e `claude-fable-5-1`; o `-Models` aceita `opus-5.5`. O log grava como foi escrito, e o scoreboard trata `claude-opus-5-5 high` e `opus-5.5 xhigh` como modelos diferentes. Aqui o esforço já os separa, mas um `opus-5.5 high` viraria uma terceira linha.
- **Base à frente da origem:** a `main` tinha 4 commits do stage 1 sem push. O Preflight aceitou (o `pull -ff-only` não falha com a base à frente), e a sessão nasceu deles e os publicou. Inofensivo aqui, mas o PR de sessão mostraria commits que a `main` remota ainda não tem.
- **Aviso inofensivo de novo:** o `.err` dos estágios do Sonnet traz o aviso `unrecognized_model` do Claude Code para `claude-sonnet-5-5`; todos rodaram normalmente.
- **Log local incompleto:** `.scratch/run-log.md` desta máquina tem 140 linhas; `docs/run-log/run-log.md` tinha 166. Copiar o local por cima, como o foreman manda, apagaria 38 linhas de 30/09. O foreman acrescentou as 12 linhas deste run à cópia.

8 Recomendações

1. **Registrar os consertos da revisão que acrescentam prova.** Quando o stage 3 escreve um teste ou fecha um critério em vez de reabrir, uma linha em `reopen-attribution.md` (com rodada 0, por exemplo) deixaria o scoreboard ver o achado. Hoje os pares do Opus 5.5 xhigh mostram 0 % em 10 revisões somadas, e pelo menos 1 dos 3 do `sonnet-5.5 high` → `opus-5.5 xhigh` teria reaberto sob o Sol max. Linhas: `sonnet-5.5 high` → `opus-5.5 xhigh` (3) e → `gpt-6.1-sol max` (8); ambas anedota.

2. **Normalizar a grafia dos modelos no log** (claude-opus-5-5 e opus-5.5 como um nome), antes que dois registros do mesmo modelo e esforço se dividam no scoreboard.
3. **Run log: mesclar, não copiar.** Ou sincronizar o `.scratch/run-log.md` desta máquina a partir de `docs/run-log/run-log.md` antes do próximo run, ou mudar o foreman para acrescentar as linhas do run à cópia.
4. **O lineup padrão novo (Sol high / Sonnet 5.5 xhigh / Sol max) está coerente com o custo:** a revisão do Opus 5.5 xhigh custou 5 vezes a do Sol max sem diferença de qualidade mensurável no scoreboard. Apoia-se em custo, não em taxa: os pares comparáveis têm 3 e 8 revisões.
5. **Abrir um CLEAN para a busca de caminho repetida** em `draw.ts`, `overlay.ts` e `hitTest.ts`, e decidir se `drawScene` merece um objeto de opções. A revisão do CLEAN-27 e a do PHY-56 anotaram; nenhum ticket existe.
6. **Testes para as três regras do CLEAN-25 sem critério** (polia solta única no meio, espaçamento entre polias ainda presas, ângulo `start` inalterado), num CLEAN de testes ou no próximo ticket que mexer em `ropePath`.
7. **A fila acabou:** nenhum ticket aberto. O próximo run depende do stage 1.

Do relatório anterior: a recomendação 6 (CLEAN do `wrapAngle`) virou o CLEAN-26 e foi mergeada aqui; a 7 (stage 1 de CLEAN-25, PHY-55 e PHY-56) também foi feita. As outras (Primary files, proxy antes de reabrir por fronteira, Codex por janela) não foram exercitadas neste run.

9 Débito humano

Nenhuma linha Débito humano: nos seis tickets, e nenhum Proxy escalated. As revisões listaram, nas Resolutions, as decisões que o proxy tomou pelo Bruno: 8 no CLEAN-25, 9 no PHY-56, 9 no PHY-55 e 5 no PHY-57. O PR #13 tem as seis linhas como Review: agent — Approve. Para o Bruno: ler as decisões do proxy no PR, mergear o PR #13 e decidir sobre as recomendações 1, 3 e 5.