

Sweatshop no PhysiSyst: v7, Foco, vetores e snap GPT-6.1 Sol no modo fast: high no stage 2, max no hard e no stage 3

Foreman, sessão `sweatshop/2026-10-04-1243`

4 de outubro de 2026

Resumo

Run do dia em três lançamentos na mesma sessão, todos com `-Models 'stage 2 gpt-6.1-sol high fast, hard gpt-6.1-sol max fast, stage 3 gpt-6.1-sol max fast'`, só para este run. O sufixo `fast` manda `service_tier=fast` ao Codex, que o cliente traduz para o tier `priority`: o dobro do preço, e o primeiro run do PhysiSyst nele. Todos os lançamentos foram processos separados (`Start-Process`). Os dois relançamentos foram para respostas do proxy.

- **Produzido:** 9 tickets da v7 mergeados na sessão, PHY-75 a PHY-83. **Cinco reaberturas** (PHY-76, PHY-78 duas vezes, PHY-82, PHY-80) e **duas perguntas** no stage 2 (PHY-78 e PHY-83), as duas respondidas pelo proxy sem escalar. As revisões abriram 4 tickets de acompanhamento, todos `blocked` para o stage 1: CLEAN-31 a CLEAN-34. PR de sessão: #17, 10 linhas, todas `Approve`. PHY-68 e PHY-76 vêm como **Review: human**. O PHY-68 entrou porque a revisão do PHY-75 anotou nele um defeito da v6 (seção 4).
- **Custo: \$67,70** a preço de lista nos 30 estágios, todos com preço, já no tier fast (2×): `gpt-6.1-sol-fast high` \$16,79 (8 implementações), `gpt-6.1-sol-fast max` \$23,08 (8 implementações hard) e \$27,83 (14 revisões). 362 min de estágio, 105,2M tokens de entrada (96,7% em cache) e 643k de saída. \$7,52 por ticket mergeado; no tier normal seriam \$3,76.
- **O que deu errado:** dois erros de ferramenta, um do driver e um do foreman. O driver leu o **Stage: blocked** do branch guardado do PHY-83 depois da resposta do proxy e encerrou com “Nothing runnable”. O foreman, ao copiar o ticket do PHY-78 para o branch dele, apagou 118 linhas, entre elas a primeira revisão com **Verdict: Reopen**. Por isso o driver contou um reopen só e não parou o PHY-78 para diagnóstico no segundo. As duas falhas foram corrigidas sem perda de código.
- **Veredito provisório sobre o fast:** vale pelo tempo, não pelo dinheiro. A geração de tokens ficou 1,8× mais rápida, e o estágio, 30 a 40% mais curto por milhão de tokens de entrada. Mas as ferramentas (testes, gate, Chromium) não aceleram. Estimativa para este run: 357 min no fast contra cerca de 560 no tier normal, ou 3h20 a menos por \$34 a mais (seção 3).


1 Linha do tempo

12:43	Lançamento 1, sessão nova <code>sweatshop/2026-10-04-1243</code> . O custo do tier fast ainda sai ? : o driver não tinha o preço.
13:03	PHY-75 (restituição alcançável, contatos do corpo) em <code>to-review</code> em 20 min. 13:17: mergeado. A revisão anota no PHY-68 da v6 que editar só o <code>e</code> não reconstrói o mundo.
13:12	O Bruno diz que o fast custa o dobro e pergunta se o tier é mesmo aplicado. O foreman confirma por telemetria (<code>service_tier= "priority"</code>) e mede 50 contra 22–29 tokens/s. O driver passa a cobrar 2× (Agent-Skills <code>dc530fb</code>). O Bruno mantém o fast e pede a comparação neste relatório.
13:47	PHY-76 (dock sob o canvas, hard) em 30 min. 13:59: reaberto (critério 8, barra de transporte cresce 2,26× em presets). 14:13: corrigido em 13 min. 14:25: mergeado.
14:43	PHY-77 (pausar quando a gravação enche) em 18 min. 15:01: mergeado.
15:24	PHY-78 (modelo de Foco e chips, hard) em 23 min. 15:38: reaberto (critério 9 contra o bloqueio de contatos do PHY-39). 15:44: o stage 2 pergunta; a revisão automática do Codex recusou a consulta ao proxy. 15:55: proxy decide.
16:07	PHY-82 (vetores no instante inicial, hard) em 22 min. 16:15: reaberto (critério 7, sonda velha depois de desfazer). 16:22: corrigido em 7 min. 16:28: mergeado.
16:30	PHY-83 (snap de orientação) pergunta em 2 min: o exemplo do critério 1 mede 6,71 px, abaixo do mínimo de 10 px. “Nothing runnable”, PR #17 aberto. Proxy decide às 16:38.
16:35	O classificador do modo automático nega o checkout da sessão. O foreman pede ao Bruno, que autoriza às 16:39.
16:39	Decisões gravadas (<code>ecb7404</code> , <code>b3aca92</code>). Ticket do PHY-78 copiado para o branch dele (<code>8b85173</code> , a cópia que apagou a revisão 1). Lançamento 2.
16:52	PHY-78 retomado em 12 min, com a integração do PHY-82 resolvida. 17:00: reaberto de novo (Foco durante o boot apaga a leitura de T). 17:11: corrigido. 17:18: mergeado.
17:25	PHY-79 (Foco por tópico nos presets) em 7 min. 17:35: mergeado.
17:45	PHY-80 (setas de v e a ao vivo) em 10 min. 17:58: reaberto (critério 6, v_0 trocado por v sem passo). 18:03: corrigido em 5 min. 18:10: mergeado.
18:21	PHY-81 (legenda clicável) em 11 min. 18:32: mergeado. 18:33: “Nothing runnable”, com o PHY-83 já em <code>to-implement</code> na sessão.
18:34	Branch guardado do PHY-83 renomeado para <code>asked/...</code> Lançamento 3.
18:47	PHY-83 em 12 min. 18:58: mergeado, com 20 mutações e 3 tickets de acompanhamento (CLEAN-32 a CLEAN-34). PR #17 com 10 linhas.

2 Métricas por estágio

As 30 linhas de `.scratch/run-log.md` da sessão `sweatshop/2026-10-04-1243`. As 16 primeiras saíram com custo ?, porque o driver ainda não tinha o preço do tier fast. O foreman as recalculou dos tokens de cada estágio, a 2× o preço do `gpt-6.1-sol`. A fórmula reproduz os \$1,749 que o driver gravou para a revisão do PHY-78 às 17:00. Implementação: `high`, ou `max` nos hard (PHY-76, PHY-78, PHY-82). Revisão: `max`.

Estágio	Esforço	Min	Entrada	Cache	Saída	Custo	Desfecho
P75 impl.	high	20	6,60 M	98 %	31 k	3,810	to-review
P75 revisão	max	14	3,10 M	95 %	27 k	2,327	mergeado
P76 impl.	max	30	6,80 M	97 %	51 k	4,473	to-review
P76 revisão	max	12	4,00 M	97 %	21 k	2,495	reaberto
P76 impl. 2	max	13	2,90 M	96 %	19 k	1,912	to-review
P76 revisão 2	max	12	2,90 M	97 %	19 k	1,864	mergeado
P77 impl.	high	18	5,50 M	98 %	25 k	3,101	to-review
P77 revisão	max	17	4,20 M	97 %	31 k	2,812	mergeado
P78 impl.	max	23	7,10 M	97 %	44 k	4,425	to-review
P78 revisão	max	14	3,60 M	97 %	26 k	2,390	reaberto
P78 impl. 2	max	7	2,10 M	95 %	11 k	1,409	perguntou
P82 impl.	max	22	7,60 M	98 %	42 k	4,551	to-review
P82 revisão	max	8	3,40 M	97 %	15 k	2,021	reaberto
P82 impl. 2	max	7	2,40 M	97 %	10 k	1,448	to-review
P82 revisão 2	max	7	1,60 M	95 %	12 k	1,184	mergeado
P83 impl.	high	2	0,32 M	90 %	2 k	0,291	perguntou
P78 impl. 3	max	12	4,50 M	97 %	23 k	2,720	to-review
P78 revisão 2	max	9	2,60 M	96 %	17 k	1,749	reaberto
P78 impl. 4	max	11	3,20 M	96 %	21 k	2,144	to-review
P78 revisão 3	max	7	2,00 M	96 %	13 k	1,399	mergeado
P79 impl.	high	7	2,50 M	96 %	12 k	1,616	to-review
P79 revisão	max	10	2,80 M	96 %	21 k	1,921	mergeado
P80 impl.	high	10	2,70 M	96 %	17 k	1,868	to-review
P80 revisão	max	13	3,60 M	96 %	28 k	2,456	reaberto
P80 impl. 2	high	5	1,90 M	96 %	6 k	1,133	to-review
P80 revisão 2	max	7	2,00 M	96 %	12 k	1,356	mergeado
P81 impl.	high	11	3,50 M	97 %	20 k	2,226	to-review
P81 revisão	max	11	2,80 M	96 %	20 k	1,862	mergeado
P83 impl. 2	high	12	4,40 M	97 %	25 k	2,743	to-review
P83 revisão	max	11	2,60 M	95 %	22 k	1,996	mergeado
Total		362	105,22 M	96,7 %	643 k	67,702	30 de 30 com preço
Implementação		210	64,02 M			39,870	16 estágios
Revisão		152	41,20 M			27,832	14 estágios
Retrabalho		90	26,00 M			16,909	5 reaberturas, impl. e revisão seguintes
Perguntas		9	2,42 M			1,700	2 estágios que pararam



Onde foi o custo. Por ticket: PHY-78 \$16,24 (83 min, duas reaberturas e uma pergunta), PHY-76 \$10,74 (67 min), PHY-82 \$9,20 (44 min), PHY-80 \$6,81, PHY-75 \$6,14, PHY-77 \$5,91, PHY-83 \$5,03, PHY-81 \$4,09, PHY-79 \$3,54. Os três hard com reabertura somaram 53 % do custo. A implementação levou 59 % do custo e 61 % da entrada.

O que se perdeu. As cinco reaberturas custaram \$16,91 e 90 min de retrabalho: implementação e revisão seguintes. A segunda do PHY-78 sozinha custou \$3,54, e veio de uma regressão na integração com o PHY-82 (seção 4). As duas perguntas custaram \$1,70. A do PHY-78 deixou só

a pergunta; a do PHY-83 parou em 2 min, antes de escrever código. Nenhum estágio perdido por falha. Em relógio, a sessão ficou parada de 16:31 a 16:39, esperando a autorização do checkout, e por 1 min às 18:33, com o bug do branch guardado.

3 Fast contra tier normal

O Bruno pediu esta comparação ao decidir manter o fast. Os tickets da v7 não são os da v6, então a comparação normaliza pelo tamanho do trabalho: minutos por milhão de tokens de entrada e por 10 k tokens de saída. O lado normal são os estágios `gpt-6.1-sol high` e `max` de 01 a 03/10 com o *rollout* do Codex ainda em disco (`~/.codex/sessions`). O lado fast são os 30 estágios deste run. O tempo de ferramenta é a soma, sem sobreposição, dos intervalos entre cada chamada e a sua saída no rollout: comandos, testes, gate, Chromium e espera por subagentes. O resto é tempo de modelo.

	Implementação		Revisão	
	normal	fast	normal	fast
Estágios medidos	7	16	26	14
Entrada mediana por estágio	1,80 M	3,35 M	1,80 M	2,85 M
Duração mediana do estágio	8,1 min	11,6 min	11,8 min	10,8 min
Tokens de saída por segundo de modelo (mediana)	24,5	44,0	23,2	40,8
Minutos por M de entrada (mediana)	4,36	3,11	6,25	3,70
Minutos por 10 k de saída (mediana)	9,9	5,8	8,3	5,3
Minutos de modelo por 10 k de saída	6,8	3,8	7,2	4,1
Ferramentas, % do tempo total	29 %	34 %	13 %	25 %
US\$ por M de entrada (mediana)	0,32	0,63	0,37	0,68

- **O tier é aplicado.** A telemetria do cliente (`RUST_LOG=codex_otel=info`) registra `service_tier="priority"`. O eco do servidor diz `default` sempre, e um valor inválido é ignorado sem erro. A prova é a velocidade: o modelo gera 1,8× mais tokens por segundo.
- **O estágio não fica 1,8× mais curto.** Por milhão de tokens de entrada, a implementação ficou 29 % mais curta e a revisão 41 %. As ferramentas não aceleram: a fatia delas subiu de 29 para 34 % na implementação e de 13 para 25 % na revisão. É o teto do ganho: quanto mais o estágio roda teste e Chromium, menos o fast ajuda.
- **A duração mediana ficou parecida** (11,6 contra 8,1 min na implementação, 10,8 contra 11,8 na revisão). Os tickets da v7 pediram 1,6 a 1,9× mais entrada por estágio. Sem normalizar, parecia que o fast não fazia nada, e foi o que o Bruno notou às 13:12.
- **O custo dobra exatamente:** US\$ por milhão de entrada vai de 0,32–0,37 a 0,63–0,68. A saída por milhão de entrada ficou parecida (5,6 contra 4,5 k na implementação, 7,1 contra 7,4 k na revisão), então o fast não fez o modelo pensar mais nem menos.
- **Neste run:** 357 min de rollout, dos quais 106 de ferramenta e 251 de modelo. No tier normal, o modelo levaria cerca de $251 \times 1,8 = 454$ min, e o run cerca de 560 min. O fast economizou umas 3h20 de relógio por \$33,85 a mais (\$67,70 contra \$33,85).
- **Limites:** 7 implementações normais é amostra pequena; o lado fast mistura `high` e `max` na implementação (as medianas são 10,2 e 12,5 min, a 44,8 e 44,0 tokens/s); e tickets diferentes não normalizam tudo. A conclusão de direção é firme (o modelo dobra a velocidade, o estágio não); os números exatos, não.

4 Atribuição das reaberturas

Cinco rodadas `reopened` neste run. O revisor foi `gpt-6.1-sol-fast max`, não o modelo do foreman (Opus), então o foreman rotulou. As linhas foram para `.scratch/reopen-attribution.md`, na tabela de 12 colunas.

Ticket	Rodada	Rótulo	Achado e porquê
PHY-76	1	S2-explicito/código	Critério 8: em presets (Atwood com gráfico, 1280 e 1920 px) a barra de transporte cresce $2,257\times$ de escala 1 para 1,6, fora de $1,6\times \pm 10\%$. A largura inversa ao zoom com <code>flexWrap</code> e o hint de preset jogam a barra para uma linha extra. Os testes de proporção só montavam a cena inicial.
PHY-78	1	S1	Critério 9 exigia contatos habilitados depois de um passo; a implementação preservava o bloqueio do PHY-39. O critério contradizia o PHY-39 e a prosa do próprio ticket; só uma decisão resolvia, e o proxy reescreveu o critério.
PHY-78	2	S2-implícito	Clicar num chip de Foco durante o boot apaga a leitura inicial de T: <code>toggleFocusGroup</code> troca a identidade de <code>docRef</code> , <code>ensureSim</code> marca <code>pendingRebuildRef</code> e o polling descarta a leitura. Regressão da integração com o PHY-82 que o stage 2 fez na retomada.
PHY-82	1	S2-explicito/código	Critério 7: a sonda fica velha ao desfazer ou arrastar de volta à geometria do mundo vivo antes do primeiro passo. Os testes só arrastavam para posições novas.
PHY-80	1	S2-explicito/código	Critério 6: depois de uma edição estrutural, um quadro a $0,5\times$ reconstrói o mundo sem passo, e a pintura troca v_0 por v com zero passos. A escolha vinha da presença no mapa de estados, que <code>syncWorld</code> preenche antes de qualquer passo.

Totais: 3 S2-explicito/código, 1 S2-implícito, 1 S1; nenhum S2-explicito/teste nem S3. Todos os achados vieram com reprodução e foram corrigidos com teste e mutação. Não há *churn*: nenhuma regressão veio de conselho de revisão anterior.

Falha anterior da revisão, em disputa. O revisor da segunda rodada do PHY-78 escreveu que o achado era “uma omissão” da primeira revisão, porque o caminho do boot já existia no código revisado. O foreman discorda: antes do PHY-82 não havia leitura de T em $t = 0$ para perder, e o PHY-82 entrou na sessão depois da primeira revisão. A linha ficou com `Review miss: unknown`, não `yes`.

Consertos da própria revisão (rodada 0). Nenhum. As revisões que mergearam fizeram consertos só de documentação: um comentário no `scheduler.ts` (PHY-77), o README (PHY-80), a ordem dos comentários (PHY-81) e um comentário no `overlay.ts` (PHY-82). Nenhum acrescentou teste, critério ou vermelho.

Achado depois da aprovação. A revisão do PHY-75 achou um defeito na v6, já aprovada: `routeDocChange` compara μ_s/μ_k , mas não o `e`. Então editar só a restituição de um par não reconstrói o mundo, e a sonda devolveu uma rota `live` sem operações. Ficou como nota no PHY-68, com o PR #16 ainda aberto (mergeado às 13:56), e não virou ticket. Linha `session-review`, `unclassified`, origem `unknown`: a consequência no App foi inferida por leitura, não reproduzida no DOM.

5 Scoreboard

Saída de `sweatshop/scripts/scoreboard.ps1` sobre PhysiSyst, SIGAA-ME, slip, **SynchroNice** e **ClassyCall**. No relatório anterior os dois últimos ficaram de fora porque os drivers deles rodavam; hoje nenhum driver estava ativo. Por isso várias linhas mudaram sem que este run as tocasse.

Implementador	Estágios	To review	Falhou	Perguntou	Mediana até review	Custo
sonnet	121	75	31	15	7m	\$10.53 (4/121)
opus-5.5	35	31	4	0	6m	\$0.72 (1/35)
gpt-6.1-sol high	38	33	0	5	8m	\$29.32 (38/38)
sonnet-5.5 high	16	15	1	0	7m	\$28.15 (16/16)
sonnet-5.5 xhigh	9	8	1	0	25m	\$35.54 (9/9)
opus-5.5 high	2	2	0	0	9m	\$2.31 (2/2)
gpt-6-astra medium	57	47	1	9	10m	\$162.72 (57/57)
gpt-6.1-sol-fast high	18	16	0	2	10m	\$21.98 (15/18)
gpt-6.1-sol-fast max	14	12	0	2	12m	\$31.19 (14/14)
fable	5	5	0	0	3m	?
gpt-6-luna	23	11	10	2	26m	?
gpt-6-sol	6	5	1	0	17m	?
gpt-5.6-sol	5	4	1	0	17m	?
gpt-6-astra	18	11	6	1	8m	?
sonnet-5 xhigh	11	6	2	3	8m	\$18.09 (11/11)
gpt-6-astra low	2	2	0	0	30m	\$19.03 (2/2)
gpt-6.1-sol max	3	1	2	0	17m	\$1.44 (1/3)

Implementador	Revisor	Reviews	Reab.	Taxa	Por S2	Taxa S2	Sem rót.	Cons. S2
sonnet	opus	68	20	29 %	1	≥1 %	19	0
?	opus	4	0	0 %	0	0 %	0	0
opus-5.5	fable-5.1	30	1	3 %	0	≥0 %	1	0
gpt-6.1-sol high	gpt-6.1-sol max	32	8	25 %	7	22 %	0	0
sonnet-5.5 high	gpt-6.1-sol max	12	3	25 %	3	25 %	0	0
sonnet-5.5 xhigh	gpt-6.1-sol max	7	3	43 %	3	43 %	0	0
opus-5.5 high	fable-5.1 high	1	0	0 %	0	0 %	0	0
opus-5.5 high	opus-5.5 xhigh	1	0	0 %	0	0 %	0	0
sonnet-5.5 high	opus-5.5 xhigh	3	0	0 %	0	0 %	0	3
sonnet-5.5 xhigh	opus-5.5 xhigh	1	0	0 %	0	0 %	0	0
gpt-6-astra medium	gpt-6-astra xhigh	10	1	10 %	1	10 %	0	0
gpt-6-astra medium	gpt-6.1-sol max	37	7	19 %	6	16 %	0	1
gpt-6.1-sol-fast high	gpt-6.1-sol-fast max	16	2	12 %	2	12 %	0	0
gpt-6.1-sol-fast max	gpt-6.1-sol-fast max	12	6	50 %	5	42 %	0	0
sonnet	fable	1	0	0 %	0	0 %	0	0
fable	fable	4	1	25 %	0	≥0 %	1	0
gpt-6-luna	gpt-6-sol	11	7	64 %	0	≥0 %	7	0
gpt-6-sol	gpt-5.6-sol	5	4	80 %	0	≥0 %	4	0
gpt-5.6-sol	gpt-6-astra	4	3	75 %	0	≥0 %	3	0
gpt-6-astra	gpt-5.6-sol	11	5	45 %	0	≥0 %	5	0
sonnet-5 xhigh	opus-5.5 xhigh	5	0	0 %	0	0 %	0	0
gpt-6-astra low	gpt-6.1-sol max	2	1	50 %	1	50 %	0	0
gpt-6.1-sol max	gpt-6.1-sol max	1	1	100 %	1	100 %	0	0

Implementador → Revisor	Rodadas	S2 expl. código	S2 expl. teste	S2 implícito	S1	S3 ruído
gpt-6.1-sol high → gpt-6.1-sol max	9	5	0	9	1	0
sonnet-5.5 high → gpt-6.1-sol max	3	5	0	2	3	0
sonnet-5.5 xhigh → gpt-6.1-sol max	3	7	0	3	2	0
sonnet-5.5 high → opus-5.5 xhigh	3	1	2	0	0	0
gpt-6-astra medium → gpt-6-astra xhigh	1	1	0	0	0	0
gpt-6-astra medium → gpt-6.1-sol max	8	11	1	4	1	0
gpt-6.1-sol-fast max → gpt-6.1-sol-fast max	6	2	0	3	1	0
gpt-6.1-sol-fast high → gpt-6.1-sol-fast max	2	2	0	0	0	0
sonnet → opus	1	1	1	0	0	0
gpt-6-astra low → gpt-6.1-sol max	1	2	0	1	0	0
gpt-6.1-sol max → gpt-6.1-sol max	1	4	0	1	0	0

Descoberta	Achados	Falha anterior da revisão (sim / conh.)	Churn (sim / conh.)
ticket-review	76	0 / 17	0 / 18

Cobertura: flags antigas e registros ausentes contam como desconhecido, não como zero. Do fim do runtime à saída do processo: 204,9s em 138 estágios medidos, 549 sem medida. Intervenções registradas: **automatic-recovery** 7, **proxy-decision** 13, **human-rescue** 2. A linha **session-review** do PHY-68 ainda não aparece: o scoreboard foi rodado antes dela ser gravada.

O que mudou desde o relatório anterior.

- **Escopo maior:** SynchroNice e ClassyCall entraram. Daí vêm as linhas novas de **gpt-6-luna**, **gpt-6-sol**, **gpt-5.6-sol**, **gpt-6-astra** sem esforço, **sonnet-5 xhigh** e **gpt-6-astra low**, e o crescimento de **sonnet** (83 → 121) e de **gpt-6-astra medium** (28 → 57).
- **Linhas novas, do fast:** high com 18 implementações, 8 deste run, e max com 14, 8 deste run. As outras vêm de um run fast do SynchroNice, e os três ? da linha high também.
- **Pares fast:** high → max com 16 revisões e 12 % de reabertura, toda por S2; neste run, 7 revisões e 1 reabertura (PHY-80). Max (hard) → max com 12 revisões e 50 % de reabertura, 42 % por S2; neste run, 7 revisões e 4 reaberturas (PHY-76, PHY-78 duas vezes, PHY-82).
- **gpt-6.1-sol high → max (normal):** de 22 para 32 revisões e de 14 para 22 % de taxa S2, só pelo escopo maior.

Como ler.

- **Fast e normal são o mesmo modelo.** O tier muda a velocidade, não os pesos, então **gpt-6.1-sol-fast high → max** (12 %, 16) e **gpt-6.1-sol high → max** (22 %, 32) medem o mesmo par em tickets diferentes. A diferença está dentro do ruído de 16 revisões.
- **O hard max reabre mais porque recebe o pior.** 42 % de taxa S2 em 12 revisões, contra 12 % do high. Neste run, os hard (PHY-76, PHY-78, PHY-82) foram os maiores e os que mais cruzaram com outros tickets da sessão. Com 12 revisões é anedota, e não diz que o max implementa pior que o high.
- **O Sol max não consertou no lugar de reabrir:** 0 na coluna de consertos nos dois pares fast.

6 Comparação

Os runs anteriores do PhysiSyst com preço, mais este. O de 02/10 tarde tem o mesmo modelo nos dois stages, no tier normal.

	02/10 tarde	03/10 madr.	03/10 tarde	Este run
Implementador	sol high	astra med.	astra med.	sol-fast high/max
Revisor	sol max	astra xhigh	sol max	sol-fast max
Estágios registrados	5	23	25	30
Tickets mergeados	2	9	8	9
Reaberturas	0	1	2	5
Impl.: falhou ou perguntou	1 de 3	3 de 13	5 de 15	2 de 16
Mediana da implementação	7 min	8 min	9 min	11,5 min
Custo médio por impl.	\$0,60	\$2,86	\$2,36	\$2,49
Mediana da revisão	9,5 min	7,5 min	11,5 min	11 min
Custo médio por revisão	\$0,58	\$2,62	\$0,78	\$1,99
Estágios perdidos (?)	0	0	0	0
Custo registrado	\$2,96	\$63,37	\$43,15	\$67,70
Custo por ticket mergeado	\$1,48	\$7,04	\$5,39	\$7,52

O custo por ticket (\$7,52) é o mais alto da tabela, acima do run com o Astra nos dois stages. Metade disso é o tier: no tier normal seriam \$3,76, abaixo dos runs com Astra. A outra parte são os tickets da v7, maiores (3,5M de entrada por estágio contra 1,7M em 03/10), e as cinco reaberturas. A revisão custou 2,5× a de 03/10 tarde (\$1,99 contra \$0,78) com o mesmo modelo e esforço: 2× pelo tier, o resto por revisões maiores.

7 Observações sobre os modelos

GPT-6.1 Sol fast (high, e max no hard), implementação

- **9 de 9 tickets mergeados, 14 de 16 estágios em to-review.** 2 a 30 min, \$0,29 a \$4,55. Nenhuma falha.
- **Mutação registrada em todos os tickets**, com a saída vermelha por teste nas costuras de DOM e de browser. O PHY-83 fechou com 20 mutações, e o PHY-81 com 12.
- **As duas perguntas foram contrato, não permissão.** O critério 9 do PHY-78 contradizia o PHY-39, e o exemplo do critério 1 do PHY-83 contradizia a própria regra de 10 px. Nenhuma pergunta de `Primary files`, o padrão que marcou os runs de 03/10.
- **Integrou a sessão no meio do ticket.** O PHY-78 foi retomado num branch anterior ao PHY-82, com conflito em `src/App.tsx`. O stage 2 resolveu o conflito, mas a integração trouxe a regressão da segunda reabertura.
- **O gate rodou fora do sandbox em vários estágios:** o Chromium não conecta dentro do sandbox do Codex. O PHY-83 o registrou no `.final`.

GPT-6.1 Sol fast (max), revisão

- **9 mergeados, 5 reabertos, 7 a 17 min, \$1,18 a \$2,81.** Reproduziu as mutações e rodou o gate antes de cada merge.
- **Quatro achados de código reais, todos com reprodução:** barra de transporte em presets (PHY-76), sonda velha depois de desfazer (PHY-82), v_0 trocado sem passo (PHY-80) e leitura de T perdida no boot (PHY-78). Todos eram casos de borda de critério explícito ou de integração.
- **Mandou para o stage 2 uma lacuna de contrato.** Na primeira revisão do PHY-78, ele escreveu que o critério 9 precisava de decisão do stage 1 ou do proxy, mas pôs `to-implement`. O stage 2 só pôde perguntar, e um estágio (\$1,41) foi gasto para isso.
- **Registrou o que achou fora do ticket** em vez de reabrir: o Foco no undo/redo (CLEAN-31), três follow-ups do snap (CLEAN-32 a 34) e a restituição do PHY-68 (só nota, sem ticket).

8 Driver e runtime

- **Preço do tier fast:** o driver registrava ? para os modelos `-fast`. Desde `dc530fb` (Agent-Skills) ele cobra $2\times$ o preço base, com self-check e mutação. As 16 linhas anteriores foram recalculadas para este relatório.
- **O branch guardado continua casando com a busca do driver** (recomendação 3 do relatório anterior, ainda aberta). Desta vez custou um relançamento: `Ticket()` procura `refs/heads/*/PHY-83-*`, achou `phy/PHY-83-...-asked-20261004-1630`, com `Stage: blocked`, e o driver terminou com o PHY-83 pronto na sessão. O foreman renomeou o branch para `asked/phy83-...` e relançou. Um conserto do driver ficou sugerido como tarefa separada.
- **A revisão automática do Codex recusou a consulta ao proxy** no stage 2 do PHY-78 (“envio de código privado a destino externo”). O stage parou e perguntou, como manda o `ticket-flow`.
- **Sandbox do Codex:** Chromium sem conexão ao DevTools e `CreateProcessWithLogonW` 1909. Os estágios rodaram o gate fora do sandbox.
- **O classificador do modo automático do Claude Code negou o checkout da sessão** pelo foreman, por interferência com uma carga de trabalho. O Bruno autorizou; 8 min parados.
- **PR de sessão sem -draft:** o #17 foi aberto pronto para revisão (recomendação antiga, ainda aberta).

9 Erro do foreman

Para retomar o PHY-78, o foreman copiou o ticket da sessão (com a decisão do proxy) por cima do ticket do branch `phy/PHY-78`, em vez de mergear, porque o merge conflitava em `src/App.tsx`. O ticket da sessão não tinha o histórico do branch: a cópia (8b85173) apagou 118 linhas. Eram as notas de mutação do primeiro stage 2, a primeira revisão inteira e a nota da pergunta. Com o **Verdict**: `Reopen` da primeira revisão apagado, o driver contou um `reopen` só e não parou o ticket no segundo. O diagnóstico obrigatório da seção “segundo `reopen`” da skill **foreman** não aconteceu antes da nova implementação; ela acertou, mas por sorte. As linhas foram restauradas do 8b85173[^] no fechamento, com o diagnóstico registrado depois do merge. Regra para o próximo run: na retomada, levar ao branch só as linhas novas do ticket (proxy, foreman), nunca o arquivo inteiro.

10 Recomendações

1. **Manter o fast quando o relógio importa.** Ele corta cerca de um terço do tempo de cada estágio pelo dobro do preço. Para um run noturno sem ninguém esperando, o tier normal faz o mesmo trabalho pela metade.
2. **Abrir um ticket para o e no routeDocChange** (achado da revisão do PHY-75). Hoje é só uma nota no PHY-68, e o defeito está na `main` desde o merge do PR #16.
3. **Driver: nome do branch guardado fora do glob do ticket.** Terceira vez (PHY-72 e PHY-74 em 03/10, PHY-83 hoje). Tarefa sugerida nesta sessão.
4. **Revisor: lacuna de contrato vai para blocked, não para to-implement.** A primeira revisão do PHY-78 sabia que precisava de decisão e mandou para o stage 2 assim mesmo. Uma linha no `ticket-flow` evitaria o estágio gasto só para perguntar.
5. **Proxy para o stage 2 no Codex** (recomendação antiga). Agora a revisão automática do Codex bloqueia a consulta; sem o foreman, as duas perguntas teriam parado a fila.
6. **Stage 1: conferir os exemplos numéricos contra as próprias regras.** O critério 1 do PHY-83 tinha um exemplo abaixo do mínimo de 10 px; o stage 2 pegou em 2 min, mas parou a fila.
7. **Triagem dos CLEAN-31 a CLEAN-34** no planner. O CLEAN-31 (Foco restaurado pelo `undo/redondo`) é o que mais afeta o usuário.
8. **Revisão humana:** PHY-76 (hard, **Review**: `human`, `dock` e `zoom`) e PHY-68 (só a nota nova), nessa ordem; depois o PHY-78 (hard, duas reaberturas, toca o `App.tsx` inteiro).

Do relatório anterior: as recomendações 3 (branch guardado), 6 (proxy no Codex) e o PR draft continuam abertas. A 2 (`Primary files`) não se repetiu neste run.

11 Decisões do proxy

As 2 linhas `Proxy decided` dos tickets deste run, as duas no stage 2. Nenhuma linha `Proxy escalated`. Ficam em `## Comments` de cada ticket; aqui, citadas na íntegra.

PHY-78 (1)

1. (**stage 2, 04/10**) manter o bloqueio estrutural (PHY-39, ADR-0004) e reescrever o critério 9: o Foco não pode esconder nem mudar a habilitação de campo nenhum, verificado no mesmo instante; contatos desabilitados após um passo é o PHY-39, não o PHY-78 — a regra do spec (“campos de edição nunca são filtrados”) é sobre o Foco, não sobre os outros bloqueios, e o critério como escrito pedia que este ticket desfizesse o PHY-39, o que ninguém decidiu. Nenhuma mudança de produção; só o teste do critério 9 (`commit test-only`) e o texto do critério. O que o teste deve asserir: (a) após `p.steps(1)`, selecionar o corpo e capturar `disabled` de cada input de forças e de `contacts.muS/muK/e` com forças ligadas; (b) `toggleFocus('forces')` e asserir que os mesmos inputs seguem no DOM com `disabled` igual ao capturado — forças `false`, contatos `true` — sem `seek(0)` antes; (c) só então

`p.seek(0)` e assertir todos `false`, ainda com forças desligadas; (d) religar forças e assertir `P`. `Mutate-verify`: a mutação “fieldset de contatos recebe `disabled={disabled || !showForces}`” (ou `hidden` nos campos com forças desligadas) deve ficar vermelha em (b); registrar a saída no ticket. Retomar da branch `phy/PHY-78-modelo-de-foco-e-chips` (fb7bb72): os outros critérios passaram com 22 mutações; `src/App.tsx` não muda.

PHY-83 (1)

1. (**stage 2, 04/10**) manter a exclusão dos segmentos curtos (é decisão do spec: “segmentos de comprimento até a tolerância não travam”) e corrigir só o exemplo de menor afastamento do critério 1, de (0.1, 0.05) para (0.16, 0.12) — com `ppm = 60`, (0.1, 0.05) mede 6,71 px (≤ 10 px, logo `null`), enquanto (0.16, 0.12) mede exatamente 12 px (0,2 m, triângulo 3-4-5), $|dx| = 9,6$ px e $|dy| = 7,2$ px cabem os dois na tolerância e o menor afastamento é o horizontal. A proposta do stage 2, (0.15, 0.1), também satisfaz (10,82 px), mas fica a 0,8 px da borda; (0.16, 0.12) está no meio da janela válida ($10 \text{ px} < L \leq 14,14 \text{ px}$). Nenhum outro critério tem a mesma inconsistência (2, 3, 6, 7 conferidos; 4, 5, 8 sem geometria).

12 Débito humano

Nenhuma linha Débito humano: nos nove tickets nem nos CLEAN-31 a CLEAN-34, e nenhum Proxy escalated. O PR #17 lista PHY-68 e PHY-76 como **Review: human** — Approve, no topo; os outros oito como **Review: agent** — Approve. Os CLEAN-31 a CLEAN-34 ficam **blocked** esperando o stage 1 (planner), e o achado do e no PHY-68 espera um ticket.