

Sweatshop 2026-09-24-1506

Lineup nova: Opus 5.5 no stage 2, Fable 5.1 no stage 3 (e como proxy)

Foreman (Claude Opus 5.5)

24 de setembro de 2026

Resumo

Foram três lançamentos do driver entre 15:06 e 16:42 (96 min), com 11 stages rodados e 82 min de stage. **Três tickets chegaram a done na sessão:** PHY-23 (o tracer da v4, corda sobre polia fixa), PHY-32 (code-split do Rapier) e CLEAN-01 (endurecimento do code-split, aberto pelo review do PHY-32). Os três têm veredito Approve e estão no [PR #8](#). Nenhum review reabriu um ticket.

Das 11 execuções, 5 não chegaram onde deviam. Nenhuma foi erro de engenharia dos modelos. Duas foram perguntas legítimas, uma foi uma pergunta desnecessária e duas foram falhas de processo do stage 3. A causa de cada uma está na seção 4, e todas já têm correção no processo.

Por ticket, a lineup nova custou **27 min de stage**. A leva de 14/09 (Sonnet no stage 2, Opus no stage 3) custou 57, com tickets bem menores. O número é pequeno demais para virar conclusão, mas aponta na mesma direção da leitura qualitativa.

1 Linha do tempo

Fim	Ticket	Stage (modelo)	Min	Resultado
15:27	PHY-23	implement (Opus)	20	ok to-review na 1ª tentativa
15:40	PHY-23	review (Fable)	13	Approve, mas parou em to-merge num PR contra o main: o card do reviewer mandava assim
15:42	PHY-32	implement (Opus)	2	parou : pergunta legítima (arquivos fora dos Primary files); o driver leu como falha
15:43	PHY-32	implement (Opus)	1	a mesma pergunta; blocked
—	PHY-32	proxy (Fable)	0,8	Decision : os 3 arquivos entram, conferido com grep
15:56	PHY-23	review (Fable)	2	falhou : gate rodado em background; a sessão acabou sem esperar o resultado
16:02	PHY-32	implement (Opus)	6	ok to-review
16:09	PHY-32	review (Fable)	7	ok merged; abriu o CLEAN-01
16:15	CLEAN-01	implement (Opus)	6	parou : usou o proxy 3 vezes, depois pediu ao humano para rodar um script node
16:20	CLEAN-01	implement (Opus)	5	ok to-review
16:28	CLEAN-01	review (Fable)	8	ok merged, com um fix pequeno do próprio review
16:42	PHY-23	review (Fable)	12	ok merged; resolveu 2 conflitos de rebase e fechou o PR #7

2 Comparação com a leva de 14/09

Os tickets são diferentes. PHY-19..21 eram bugs de layout e harness, com diffs pequenos. PHY-23 é o ticket de arquitetura da v4 (19 arquivos, +1145 linhas, ADR novo). Leia a tabela como contexto, não como corrida.

	14/09 Sonnet → Opus	24/09 Opus 5.5 → Fable 5.1
Tickets que chegaram a done	2 (PHY-19, PHY-21)	3 (PHY-23, PHY-32, CLEAN-01)
Minutos de stage, somados	114	82
Minutos de stage por ticket em done	57	27
Stage 2 que chegou a to-review : mediana	10 min ($n = 5$)	6 min ($n = 3$)
Stage 3 que fez merge: mediana	10 min ($n = 3$)	8 min ($n = 3$)
Reviews que reabriram o ticket	3 de 6	0 de 5
Execuções do stage 2 que pararam	2 de 7	3 de 5 (2 legítimas)
Falhas de processo no stage 3	0	2 (card, background)
Ticket que terminou blocked esperando o humano	1 (PHY-20)	0

A diferença que mais pesa é o *retrabalho*. Na leva de 14/09, metade dos reviews mandou o ticket de volta, e o PHY-20 levou dois ciclos completos até parar em **blocked**. Aqui nenhum review reabriu, e o custo extra veio do processo: as perguntas e o card desatualizado. Isso é mais barato de corrigir do que a qualidade do código.

3 O que cada modelo fez

Stage 2: Opus 5.5 (high)

- **PHY-23 passou de primeira num ticket de arquitetura.** Os 14 critérios foram atendidos. Os erros medidos ficaram muito abaixo da tolerância: no pior caso, 0,05% em a , 0,79% em T e 0,26 mm em $|\text{caminho}-L|$. A tabela de mutate-verify tem 7 mutações, cada uma com o teste que ficou vermelho e o valor medido. É exatamente o registro que o `AGENTS.md` pede.
- **Deixa as decisões à vista.** Listou quatro decisões que o ticket não resolvia. A principal é o critério 1, lido como coleções ausentes e opcionais. Também declarou a única linha que escreveu fora dos Primary files.
- **Respeita a fronteira do escopo.** No PHY-32, em vez de mexer fora dos Primary files, diagnosticou a causa (TIMESTEP prendia o Rapier no chunk de entrada), mediu um protótipo (de 2378 kB para 258 kB), reverteu e perguntou. Levou 2 minutos.
- **Usou bem o proxy.** No CLEAN-01 chamou o proxy três vezes, uma delas para um guard contra loop de reload que o ticket não previa, e dobrou as respostas no ticket como manda a regra.
- **Ponto fraco: ainda pergunta o que podia resolver sozinho.** Na tentativa 1 do CLEAN-01, pediu ao humano para rodar um script `node`, porque o allowlist não inclui `node`. O review do Fable mostrou depois que `npm exec` resolvia. A tentativa se perdeu por falta de engenho com as ferramentas, não por falta de decisão.

Stage 3: Fable 5.1 (high)

- **Verifica em vez de confiar.** Rodou o gate de novo em todo review e reproduziu as verificações live por conta própria (Chromium headless nos PHY-23 e CLEAN-01). No CLEAN-01 ainda aplicou uma mutação e viu o teste ficar vermelho.
- **Olha além do diff.** No PHY-23 achou um bug que já existia: `resetForces` não zera o torque, e mediu $\omega = 40,4$ rad/s contra 3 rad/s esperados. Abriu o PHY-34 em vez de corrigir no review. No PHY-32 abriu o CLEAN-01 para a falha de chunk em cache. Nos dois casos respeitou o limite do “fix pequeno”.
- **Faz o trabalho de merge direito.** No último review do PHY-23, resolveu dois conflitos de rebase contra o PHY-32, entre eles o import do TIMESTEP, que tinha mudado de lugar. Checou a separação entre commits de teste e de código depois do rebase e fechou o PR #7 com um comentário.
- **Pontos fracos: dois tropeços de processo.** (1) Rodou o gate em background, e a sessão

headless acabou antes do resultado. (2) Um `/code-review` rodou no intervalo errado de commits, e o Fable estacionou os achados como não verificados no CLEAN-01, em vez de rodar de novo no intervalo certo. O PR contra o `main` no primeiro review foi culpa do card, não do modelo: ele seguiu a instrução mais específica.

Proxy: Fable 5.1 (high)

A regra nova entrou no meio da leva. Rendeu 4 decisões e nenhuma escalação.

- **PHY-32**, chamado por mim: levou 48 s, 8 chamadas de ferramenta e cerca de 69 mil tokens. Não aceitou o escopo proposto sem checar: fez um `grep` por imports de valor do módulo do simulador e confirmou que `accelerationTracker.ts` era o único além do `App.tsx`.
- **CLEAN-01**, chamado pelo stage 2, com 3 decisões: o guard de reload de 10 s com `sessionStorage`, a isenção de testes na regra de lint e a linha em `overlay.test.ts`. O review conferiu as três contra o código e aprovou.

O proxy tirou o humano do caminho crítico. Pelo processo antigo, PHY-32 e CLEAN-01 teriam ficado `blocked` até a próxima leva.

4 Incidentes e correções

Incidente	Causa	Correção
PHY-23 parado em <code>to-merge</code> com PR contra o <code>main</code>	o card <code>reviewer.md</code> ainda mandava usar o <code>main</code> como base e fazer merge por PR	card corrigido (<code>dbfc90b</code>)
Pergunta do PHY-32 perdida	o driver só reconhece pergunta quando a mensagem termina em “?”, então tratou como falha e apagou o branch	<code>blocked</code> gravado pelo próprio stage agora conta como pergunta, e a mensagem inteira vai para o ticket (<code>b56a5cc</code>)
Review do PHY-23 morto em 2 min	gate em background numa sessão headless	regra “nada em background” no <code>ticket-flow</code> (<code>901d6c3</code>)
Tentativa perdida no CLEAN-01	pediu ao humano um comando fora do allowlist	nenhuma ainda (ver seção 6)
Stages tentando tocar o beep	a preferência do beep, salva na memória do projeto, foi lida pelos stages	memória restrita ao foreman
Driver caiu duas vezes gravando o <code>run-log.md</code>	erro meu : o <code>tail -F</code> do meu monitor travava o arquivo, e o <code>TaskStop</code> deixou o <code>tail</code> órfão	processo morto; linhas restauradas à mão; monitor novo lê a saída do driver
Check-in das 16:00 não saiu	o cron da sessão não disparou (causa desconhecida)	troquei por um timer em background

5 Limites desta avaliação

- São 3 tickets de um lado e 2 do outro, com tickets de natureza diferente. O stage 3 teve só 3 reviews completos.
- O driver grava só a última mensagem de cada sessão, sem tokens nem custo por stage. O único número de custo é o do proxy chamado por mim.
- Os minutos incluem o gate (Vitest, build e Chromium headless), que não depende do modelo.
- Três regras mudaram no meio da leva (proxy, card do reviewer, background). Os stages depois das 15:54 rodaram num processo melhor que os primeiros.

6 Sua vez

1. **PR #8:** 3 tickets com Approve. O PHY-23 está no topo, com Review: human. A decisão a conferir é o critério 1, lido como coleções ausentes e opcionais, sem [] literal.
2. **Achados não verificados no CLEAN-01:** o /code-review desviado encontrou dois possíveis furos. O autosave com debounce não é gravado antes do reload, e a regra de lint deixa passar `import { type X }`. Merecem um ticket.
3. **Push dos skills:** b56a5cc e 901d6c3 estão só no Agent-Skills local. Sem esse push, a outra máquina roda o driver sem as correções.
4. **Decidir:** pôr node no allowlist dos stages, ou escrever no ticket-flow que scripts rodam via npm exec.
5. **Próxima leva:** PHY-24 e PHY-26 estão desbloqueados, e o PHY-34 está na fila.